

UNIVERSIDAD DE SANTIAGO DE CHILE

Facultad de Ingeniería

Departamento de Ingeniería Informática

TerraMatch

Sistema de estimación de satisfacción inmobiliaria basado en información
geoespacial

Segunda Evaluación

Informe Final

Integrantes del Grupo:

Valentina Del Pilar Barría

Felipe Baeza Muñoz

Byron Caices Lima

Catalina López

Jaime Antonio Riquelme Olguín

Diego Ignacio Rojas Bustos

Profesor:

Francisco Parra O.

Enero 2026

Resumen Ejecutivo

El mercado inmobiliario chileno enfrenta una crisis de acceso caracterizada por el requisito de un 20 % de pie inicial para créditos hipotecarios, equivalente a aproximadamente 32 veces el ingreso mediano del país. Esta realidad ha generado consumidores cada vez más exigentes que buscan maximizar la satisfacción de su inversión inmobiliaria, demandando herramientas objetivas que permitan evaluar propiedades más allá del precio.

En este contexto, **TerraMatch** surge como un sistema de apoyo a la decisión que integra información geoespacial para estimar la satisfacción residencial potencial de propiedades en venta. El proyecto se desarrolla sobre cuatro comunas de la Región Metropolitana de Santiago: Estación Central, La Reina, Ñuñoa y Santiago Centro, seleccionadas por su diversidad socioeconómica y heterogeneidad urbana.

La metodología implementada comprende cinco etapas principales: (1) extracción automatizada de 7.702 propiedades mediante web scraping, (2) geocodificación utilizando Google Maps API en EPSG:32719, (3) cálculo de 42 variables espaciales mediante distancias a puntos de interés, (4) diseño de un índice de satisfacción residencial, y (5) entrenamiento de modelos predictivos mediante Machine Learning.

Los resultados demuestran que el modelo LightGBM alcanza un **R^2 de 0.8635** con RMSE de 0.3357 y baja autocorrelación espacial de residuos (Moran's $I = 0.0695$), indicando ausencia de sesgo geográfico. Las variables más importantes incluyen la distancia a centros de salud (50 % de importancia), precio por m² (16 %) y densidad comercial (8 %).

El sistema se ha implementado como una aplicación web funcional con backend en FastAPI y frontend en Nuxt.js, permitiendo a los usuarios explorar propiedades, obtener predicciones de satisfacción y recibir recomendaciones personalizadas según perfiles de usuario (familia, profesional joven, inversionista, adulto mayor).

Índice

Resumen Ejecutivo	1
1. Introducción	5
1.1. Contexto y Motivación	5
1.2. Objetivos	5
1.2.1. Objetivo General	5
1.2.2. Objetivos Específicos	6
1.3. Preguntas de Investigación	6
1.3.1. Pregunta Principal	6
1.3.2. Preguntas Secundarias	6
1.3.3. Hipótesis de Trabajo	6
1.4. Alcance y Limitaciones del Proyecto	7
2. Marco Teórico	8
2.1. Satisfacción Residencial y Calidad de Vida Urbana	8
2.2. Modelos Hedónicos y Valor de la Vivienda	8
2.3. Accesibilidad Urbana y Servicios	8
2.4. Análisis Espacial y Autocorrelación	9
2.5. Machine Learning en Predicción Inmobiliaria	9
3. Área de Estudio	10
3.1. Ubicación Geográfica	10
3.2. Comunas del Estudio	12
3.3. Justificación de la Selección	12
4. Datos y Metodología	14
4.1. Fuentes de Datos	14
4.2. Procesamiento de Datos	14
4.3. Metodología de Análisis Espacial	15

4.3.1. Cálculo de Distancias	15
4.3.2. Cálculo de Densidades	16
4.3.3. Índices de Accesibilidad	16
4.4. Diseño del Proxy de Satisfacción	18
4.5. Modelamiento Predictivo	19
4.6. Herramientas y Librerías	19
5. Aplicación Web y Chatbot de Inteligencia Artificial	20
5.1. Arquitectura de la Aplicación	20
5.2. Chatbot Conversacional con Gemini	20
5.2.1. Flujo de Conversación	20
5.2.2. Ejemplo de Interacción	21
5.3. Sistema de Validación Financiera	21
5.3.1. Parámetros Financieros	21
5.3.2. Cálculo de Capacidad de Endeudamiento	22
5.3.3. Tabla de Referencia Rápida	22
5.3.4. Penalización por Deudas	22
5.4. Integración con el Backend	23
5.5. Presentación de Resultados	23
5.6. Tecnologías de Implementación	23
6. Resultados	25
6.1. Caracterización del Dataset Inmobiliario	25
6.2. Análisis por Comuna	26
6.3. Estadísticas de Accesibilidad	27
6.4. Análisis de Correlaciones	28
6.5. Rendimiento de los Modelos Predictivos	29
6.6. Importancia de Variables	31
6.7. Validación Espacial	32

6.8. Distribución Espacial de la Satisfacción Predicha	33
7. Discusión	35
7.1. Interpretación de Resultados	35
7.2. Verificación de Hipótesis	35
7.3. Comparación con Literatura	35
7.4. Implicancias Prácticas	36
7.5. Limitaciones del Estudio	36
7.6. Trabajo Futuro	37
8. Conclusiones	38
8.1. Síntesis de Hallazgos	38
8.2. Cumplimiento de Objetivos	38
8.3. Contribución del Proyecto	38
8.4. Recomendaciones	39
8.5. Reflexión Final	39
Referencias	41
A. Anexos	42
A.1. Anexo A: Tablas Complementarias	42
A.2. Anexo B: Figuras Adicionales	43
A.3. Anexo C: Cronograma Ejecutado	45
A.4. Anexo D: Enlaces y Recursos	45

1. Introducción

1.1. Contexto y Motivación

El mercado inmobiliario chileno enfrenta crecientes barreras de acceso asociadas al alto costo del pie hipotecario y a restricciones crediticias. El pie hipotecario del 20 % equivale a aproximadamente 32 veces el ingreso mediano del país, lo que excluye a numerosos hogares tanto de créditos bancarios como de subsidios estatales BioBio Chile y CIPER Chile, 2025. Entre 2021 y 2023, la demanda de viviendas se contrajo significativamente, con caídas en ventas y mayores desistimientos, observándose en 2025 un stock cercano a 70.000 unidades disponibles.

El estudio IPSOS 2025 evidencia brechas notables de satisfacción entre propietarios (74 %) y arrendatarios (39 %), reforzando la necesidad de herramientas objetivas para comparar alternativas inmobiliarias IPSOS, 2025. Las decisiones de compra suelen basarse en información fragmentada, centrada en el precio y atributos internos de la vivienda, dejando en segundo plano variables territoriales clave como:

- Relación precio/m² y costo total de la propiedad
- Seguridad y presencia de servicios de emergencia cercanos
- Acceso a transporte público y conectividad urbana
- Proximidad a educación, salud y comercio
- Acceso a áreas verdes y espacios recreativos
- Condiciones de habitabilidad (tamaño, distribución y privacidad)

En este contexto surge **TerraMatch**, un sistema que integra análisis geoespacial y modelamiento predictivo para estimar la satisfacción residencial potencial de propiedades inmobiliarias. La propuesta combina atributos internos de la vivienda con variables geoespaciales del entorno urbano, permitiendo una evaluación objetiva y comparable entre distintas áreas urbanas, reduciendo así la asimetría de información en el mercado.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar un sistema de recomendación inmobiliaria que estime la satisfacción residencial potencial, integrando atributos internos de la vivienda con variables geoespaciales del entorno urbano, utilizando técnicas de análisis espacial y *Machine Learning* para apoyar la toma de decisiones de compra en la Región Metropolitana de Santiago.

1.2.2. Objetivos Específicos

1. Integrar y normalizar 29 datasets geoespaciales en el sistema de referencia EPSG:32719, asegurando control de calidad y consistencia espacial.
2. Calcular métricas espaciales relevantes (distancias, densidades e índices de accesibilidad) y asociarlas a 7.702 propiedades inmobiliarias geocodificadas.
3. Diseñar un proxy de satisfacción residencial que combine variables económicas, atributos físicos y características del entorno urbano.
4. Entrenar y validar un modelo predictivo basado en *Machine Learning*, evaluando su desempeño mediante métricas estadísticas y análisis de autocorrelación espacial.
5. Implementar un dashboard interactivo que permita explorar los resultados del análisis y facilitar la interpretación de la satisfacción residencial estimada.

1.3. Preguntas de Investigación

1.3.1. Pregunta Principal

¿Qué factores hacen que una vivienda sea satisfactoria para vivir en el contexto urbano de Santiago de Chile?

1.3.2. Preguntas Secundarias

- ¿Qué peso tienen los factores espaciales (acceso a servicios, transporte y áreas verdes) respecto al precio y atributos internos de la vivienda?
- ¿Existen patrones territoriales y diferencias sistemáticas entre comunas en la satisfacción residencial predicha?
- ¿Cómo varían los determinantes de satisfacción según el perfil de usuario (familia, profesional joven, inversionista)?
- ¿Es posible predecir la satisfacción residencial con precisión suficiente para apoyar decisiones de compra?

1.3.3. Hipótesis de Trabajo

- **H1:** Los factores espaciales externos influyen significativamente en la satisfacción residencial, más allá del precio.

- **H2:** Existe autocorrelación espacial positiva en la satisfacción residencial, formando clusters territoriales.
- **H3:** Los determinantes de satisfacción varían según el perfil de usuario considerado.
- **H4:** Incorporar variables geoespaciales mejora la capacidad predictiva frente a modelos basados solo en atributos internos.

1.4. Alcance y Limitaciones del Proyecto

Alcance geográfico: El estudio cubre cuatro comunas de la Región Metropolitana: La Reina, Ñuñoa, Santiago Centro y Estación Central, representando un gradiente urbano desde zonas residenciales de baja densidad hasta el centro histórico y administrativo.

Datos de propiedades: Se analizaron 7.702 propiedades en venta (5.135 departamentos y 2.567 casas), con precios entre 800 y 73.000 UF y superficies entre 16 y 900 m².

Limitaciones principales:

- Cobertura geográfica limitada a 4 comunas de la RM
- Ausencia de variables de antigüedad, estado de conservación u orientación
- Datos estáticos (2025) sin dinámica temporal del mercado
- Sin información de gastos comunes, contribuciones o mantenimiento
- Solo propiedades en venta (no arriendos)

2. Marco Teórico

El proyecto TerraMatch se fundamenta en tres ejes conceptuales complementarios que permiten abordar el problema de la satisfacción residencial desde una perspectiva integral: (1) accesibilidad urbana y provisión de servicios, (2) economía urbana y modelos hedónicos, y (3) análisis espacial y autocorrelación territorial.

2.1. Satisfacción Residencial y Calidad de Vida Urbana

La satisfacción residencial se entiende como la adecuación entre las necesidades del hogar y las condiciones del entorno habitacional. La literatura distingue dimensiones funcionales (acceso a servicios, movilidad, equipamiento) y dimensiones simbólicas (seguridad percibida, identidad barrial, sentido de pertenencia) Bonaiuto et al., 2015; Marans, 2015.

Estudios recientes demuestran que la satisfacción residencial está fuertemente influenciada por factores territoriales que van más allá de las características físicas de la vivienda Park, 2020. En particular, la proximidad a servicios urbanos, la calidad del transporte público y el acceso a áreas verdes emergen como determinantes significativos de la calidad de vida percibida.

2.2. Modelos Hedónicos y Valor de la Vivienda

Desde la economía urbana, el precio de la vivienda actúa como un agregador de las amenidades y condiciones del entorno Lancaster, 1966; Rosen, 1974. Los modelos hedónicos descomponen el valor de la vivienda en atributos internos (superficie, dormitorios, baños) y atributos externos (accesibilidad, calidad ambiental, seguridad), constituyendo una base teórica sólida para interpretar la influencia del entorno en la satisfacción residencial Brueckner, 2011; Freeman, 2003.

La aplicación de estos modelos en el contexto latinoamericano ha demostrado que la proximidad a transporte masivo, parques y servicios de salud explica una parte significativa de la variación espacial del valor residencial Alvarez, Gutierrez et al., 2021; Zhang et al., 2019.

2.3. Accesibilidad Urbana y Servicios

El concepto de accesibilidad urbana puede modelarse de múltiples formas: distancia mínima, tiempo de viaje, cobertura dentro de radios definidos o densidad de servicios Geurs y van Wee, 2004; Handy, 1997. En ausencia de datos de red vial completos, la distancia euclidiana ofrece un estimador consistente para comparaciones relativas a escala comunal Talen, 2003; Wei, 2018.

Los índices compuestos de accesibilidad permiten integrar dimensiones heterogéneas (educación, salud, transporte, comercio) en una escala común, facilitando la interpretación y comparación entre

territorios. La definición de radios de influencia se alinea típicamente con umbrales caminables: 300 m (5 min), 600 m (10 min) y 1000 m (15 min).

2.4. Análisis Espacial y Autocorrelación

El análisis espacial permite identificar patrones territoriales y clusters de valores similares mediante indicadores como el Índice de Moran Anselin, 1995. Este indicador mide la autocorrelación espacial, es decir, el grado en que valores cercanos tienden a ser similares entre sí.

En el contexto de modelos predictivos, verificar la autocorrelación espacial de los residuos es fundamental para validar que el modelo no incorpore sesgos territoriales sistemáticos Fotheringham et al., 2002; O'Sullivan y Unwin, 2010. Un valor de Moran's I cercano a cero indica independencia espacial, sugiriendo que el modelo captura adecuadamente la estructura territorial.

2.5. Machine Learning en Predicción Inmobiliaria

En la última década, los modelos de aprendizaje automático (Random Forest, Gradient Boosting, LightGBM) han demostrado mejoras sustanciales en precisión frente a enfoques lineales tradicionales, especialmente cuando se integran variables espaciales y socioeconómicas Hoon et al., 2020; Li et al., 2020.

LightGBM, en particular, ofrece ventajas significativas para datos tabulares con alta dimensionalidad: eficiencia computacional, manejo de variables categóricas y capacidad para capturar relaciones no lineales Lynch, 2025. Herramientas de explicabilidad como SHAP permiten identificar contribuciones locales y globales de variables, complementando la interpretabilidad de modelos de árboles Lundberg y Lee, 2017.

3. Área de Estudio

3.1. Ubicación Geográfica

La Región Metropolitana de Santiago se ubica en la zona central de Chile, entre 32°55' y 34°19' S y 69°46' y 71°43' O. Es una región sin litoral, con capital en Santiago y un valle intermedio entre la Cordillera de los Andes y la de la Costa. El estudio se centra en cuatro comunas contiguas que representan un gradiente urbano característico de Santiago (Figura 1).

Chile Continental Ubicación de la Región Metropolitana




Figura 1: Ubicación de la Región Metropolitana de Santiago en el contexto nacional

3.2. Comunas del Estudio

Las cuatro comunas seleccionadas representan la heterogeneidad del Gran Santiago:

Tabla 1: Características de las comunas del área de estudio

Comuna	Superficie	Característica Principal	Propiedades
Santiago Centro	22.4 km ²	Centro histórico y administrativo	1.110
Estación Central	14.1 km ²	Alta densificación y conectividad	2.587
Ñuñoa	16.9 km ²	Residencial mixto consolidado	2.087
La Reina	23.4 km ²	Baja densidad, mayor ingreso	1.918
Total	76.8 km²		7.702




Figura 2: Mapa de ubicación del área de estudio: las 4 comunas analizadas en la Región Metropolitana

3.3. Justificación de la Selección

La selección de estas cuatro comunas responde a criterios metodológicos específicos:

- **Diversidad socioeconómica:** Desde estratos altos en La Reina hasta medios-bajos en Estación Central
- **Heterogeneidad urbana:** Zonas de alta densificación vertical versus sectores residenciales tradicionales
- **Contiguidad espacial:** Reduce sesgos por diferencias macro-regionales y facilita comparar condiciones urbanas
- **Disponibilidad de datos:** Alta cantidad de propiedades en venta y buena cobertura de servicios urbanos

En términos de movilidad, el área incluye corredores de transporte masivo (Línea 1 y Línea 3 de metro, ejes de buses troncales) que concentran accesibilidad en el centro, mientras que sectores residenciales de menor densidad dependen más del transporte privado y la accesibilidad local.

4. Datos y Metodología

4.1. Fuentes de Datos

Se integraron 29 datasets geospaciales provenientes de múltiples fuentes, organizados en siete macro-categorías:

Tabla 2: Categorías de datos geospaciales utilizados

Categoría	Ejemplos	Fuente
Educación	Colegios, jardines, universidades	IDE Chile, MINEDUC
Salud	Hospitales, consultorios, farmacias	MINSAL, OSM
Transporte	Metro, paraderos de bus, ciclovías	Metro de Santiago, DTPM
Seguridad	Comisarías, cuarteles, bomberos	Carabineros, Bomberos
Comercio	Centros comerciales, supermercados	OSM, Google Maps
Entorno	Parques, plazas, áreas verdes	MINVU, Municipios
Propiedades	Casas y departamentos en venta	Portal Inmobiliario

Datos inmobiliarios: Se extrajeron 7.702 propiedades en venta mediante web scraping de Portal Inmobiliario, incluyendo precio en UF, superficie útil y total, tipo de vivienda, número de dormitorios y baños, y dirección textual. Las propiedades se geocodificaron utilizando Google Maps API, obteniendo coordenadas en el sistema EPSG:32719 (UTM Zone 19S).

4.2. Procesamiento de Datos

El preprocesamiento siguió un pipeline estructurado de control de calidad:

1. **Normalización de CRS:** Todos los datasets reproyectados a EPSG:32719
2. **Filtrado espacial:** Selección de elementos dentro del área de estudio con buffer de inclusión
3. **Validación geométrica:** Corrección de geometrías inválidas y eliminación de duplicados
4. **Estandarización de atributos:** Homogenización de campos y control de valores nulos
5. **Geocodificación:** Conversión de direcciones textuales a coordenadas geográficas




Figura 3: Distribución de propiedades por comuna y tipo de vivienda

4.3. Metodología de Análisis Espacial

La metodología se organiza en tres fases principales:

Fase 1 - Preparación de datos: Normalización de 29 datasets y consolidación de 7.702 propiedades geocodificadas con sus atributos.

Fase 2 - Características espaciales: Generación de una grilla regular de 3.149 puntos (espaciamento de 250 m) y cálculo de métricas espaciales:

- 21 distancias mínimas a categorías de servicios
- 42 densidades de servicios en radios de 300, 600 y 1000 m
- 9 índices compuestos de accesibilidad (educación, salud, transporte, seguridad, comercio, entorno)

Fase 3 - Modelamiento predictivo: Construcción de un proxy de satisfacción residencial, selección de 42 features y entrenamiento de modelos de Machine Learning con validación cruzada.

4.3.1. Cálculo de Distancias

Para cada punto de la grilla se calculó la distancia mínima a cada categoría de servicio utilizando estructuras de datos espaciales (cKDTree), reduciendo la complejidad computacional de $O(N \times M)$ a $O(N \log M)$:

$$d_{i,k} = \min_j \sqrt{(x_{g_i} - x_{s_j})^2 + (y_{g_i} - y_{s_j})^2} \quad (1)$$

donde $d_{i,k}$ es la distancia del punto i al servicio más cercano de categoría k .

4.3.2. Cálculo de Densidades

Las densidades se calcularon contando servicios dentro de radios definidos y normalizando por área:

$$\rho_{i,k,r} = \frac{n_{i,k,r}}{\pi r^2} \times 10^6 \quad [\text{servicios/km}^2] \quad (2)$$

Los radios seleccionados (300 m, 600 m, 1000 m) corresponden a umbrales caminables que representan 5, 10 y 15 minutos de caminata respectivamente.




Figura 4: Distribución de distancias y densidades calculadas para las principales categorías de servicios

4.3.3. Índices de Accesibilidad

Las distancias y densidades se combinaron en índices compuestos por dimensión, normalizados a una escala de 1 a 10:




Figura 5: Índices de accesibilidad por dimensión: educación, salud, transporte, seguridad, comercio y entorno

Se construyeron además tres índices superiores que integran las dimensiones anteriores:

- **Índice de Vida Urbana:** Combina transporte, comercio y servicios
- **Índice de Calidad de Vida:** Integra salud, educación y entorno
- **Índice de Habitabilidad Global:** Síntesis ponderada de todas las dimensiones




Figura 6: Índices superiores: vida urbana, calidad de vida y habitabilidad global

4.4. Diseño del Proxy de Satisfacción

El proxy de satisfacción residencial se construyó combinando tres componentes:

1. **Valor económico relativo:** Precio por m² normalizado por comuna (invertido, menor precio = mayor satisfacción potencial)
2. **Atributos físicos:** Superficie útil, dormitorios por habitante, ratio baños/dormitorios
3. **Accesibilidad espacial:** Índices de accesibilidad a servicios urbanos

El proxy se ajusta a cinco perfiles de usuario, modificando los pesos de cada dimensión:

Tabla 3: Perfiles de usuario y sus prioridades

Perfil	Prioridades
Familia con niños	Espacio, educación, seguridad, áreas verdes
Profesional joven	Transporte, comercio, precio accesible
Inversionista	ROI, transporte, seguridad
Adulto mayor	Salud, seguridad, áreas verdes, accesibilidad
Balanceado	Equilibrado en todas las dimensiones

4.5. Modelamiento Predictivo

Se compararon dos algoritmos de Machine Learning:

- **Random Forest:** Modelo baseline con 100 árboles
- **LightGBM:** Gradient Boosting optimizado para datos tabulares

La evaluación utilizó partición entrenamiento/prueba (80/20) y validación cruzada de 5 folds, reportando R^2 , RMSE y MAE. Adicionalmente, se verificó la autocorrelación espacial de residuos mediante el Índice de Moran para detectar posibles sesgos territoriales.

4.6. Herramientas y Librerías

El pipeline se implementó en Python 3.12 utilizando:

- **Datos espaciales:** GeoPandas, Shapely, pyproj
- **Análisis:** Pandas, NumPy, SciPy
- **Machine Learning:** scikit-learn, LightGBM
- **Visualización:** Matplotlib, Seaborn, Folium
- **Análisis espacial:** PySAL, libpysal

5. Aplicación Web y Chatbot de Inteligencia Artificial

Además del modelo predictivo, TerraMatch implementa una aplicación web completa con un **chatbot conversacional basado en Inteligencia Artificial** que permite a los usuarios interactuar de manera natural para encontrar propiedades y recibir asesoría financiera personalizada.

5.1. Arquitectura de la Aplicación

El sistema se compone de tres capas principales:

Tabla 4: Arquitectura técnica de TerraMatch

Capa	Tecnología	Función
Frontend	Nuxt.js 3 + Vue.js	Interfaz de usuario y chatbot
Backend	FastAPI + Python	API REST y modelos ML
Base de datos	PostgreSQL + PostGIS	Datos espaciales y propiedades
IA Conversacional	Gemini 2.5 Flash	Procesamiento de lenguaje natural

5.2. Chatbot Conversacional con Gemini

El chatbot utiliza el modelo **Gemini 2.5 Flash** de Google para mantener conversaciones naturales en español chileno. El asistente está diseñado para:

- Recopilar preferencias del usuario de forma conversacional (no como formulario)
- Validar la capacidad financiera del usuario en tiempo real
- Generar búsquedas de propiedades basadas en la conversación
- Presentar resultados de manera amigable y personalizada
- Ofrecer alternativas cuando el presupuesto no es suficiente

5.2.1. Flujo de Conversación

El chatbot implementa un flujo estructurado de 6 fases:

1. **Saludo inicial:** Presentación y pregunta sobre tipo de propiedad
2. **Recopilación de preferencias:** Comuna, dormitorios, superficie, precio
3. **Validación financiera:** Ingreso mensual y capacidad de endeudamiento

4. **Búsqueda:** Generación automática de parámetros y consulta al backend
5. **Presentación de resultados:** Análisis y recomendación de las mejores opciones
6. **Refinamiento:** Ajuste de búsqueda según feedback del usuario

5.2.2. Ejemplo de Interacción

Usuario: “Hola, busco un depto en Ñuñoa”

Chatbot: “¡Hola! Qué buena elección Ñuñoa. Es una comuna muy cotizada. ¿Tienes algún rango de precio en mente? Y cuéntame, ¿cuántos dormitorios necesitas?”

Usuario: “Unos 3500 UF máximo, 2 dormitorios”

Chatbot: “Perfecto, 3.500 UF con 2 dormitorios en Ñuñoa es un rango bastante realista. Antes de buscar, ¿podrías contarme aproximadamente cuánto es tu ingreso mensual? Esto me ayuda a verificar que el financiamiento sea viable.”

Usuario: “Gano como 2 palos”

Chatbot: “Con \$2.000.000 mensuales, tu cuota máxima sería de unos \$500.000 aprox. Eso te permite un crédito de hasta 3.200 UF aproximadamente. Te recomiendo buscar en el rango de 2.500-3.200 UF para mayor comodidad financiera. ¿Te parece si busco en ese rango?”

5.3. Sistema de Validación Financiera

Una de las funcionalidades más innovadoras del chatbot es su capacidad para **validar la capacidad financiera del usuario** en tiempo real durante la conversación.

5.3.1. Parámetros Financieros

El sistema utiliza reglas bancarias chilenas configurables:

Tabla 5: Parámetros de validación financiera

Parámetro	Valor
Cuota máxima sobre ingreso	25 %
Tasa de interés anual (promedio)	5.5 %
Plazo del crédito hipotecario	25 años
Pie mínimo exigido	20 %
Valor UF referencial	\$37.500 CLP

5.3.2. Cálculo de Capacidad de Endeudamiento

El sistema calcula automáticamente el precio máximo que el usuario puede pagar utilizando la fórmula de anualidad:

$$\text{Cuota}_{max} = \text{Ingreso} \times 0,25 \quad (3)$$

$$\text{Monto}_{credito} = \text{Cuota}_{max} \times \frac{1 - (1 + r)^{-n}}{r} \quad (4)$$

$$\text{Precio}_{max} = \frac{\text{Monto}_{credito}}{1 - \text{Pie}} \quad (5)$$

Donde r es la tasa mensual ($5.5\%/12$) y n es el número de cuotas ($25 \times 12 = 300$).

5.3.3. Tabla de Referencia Rápida

El chatbot utiliza una tabla de referencia para dar respuestas inmediatas:

Tabla 6: Capacidad de compra según ingreso mensual

Ingreso Mensual	Precio Máximo (UF)	Cuota Aprox.
\$1.000.000	2.000 UF	\$230.000
\$1.500.000	3.000 UF	\$350.000
\$2.000.000	4.200 UF	\$480.000
\$2.500.000	5.500 UF	\$600.000
\$3.000.000	6.800 UF	\$720.000
\$4.000.000	9.200 UF	\$960.000
\$5.000.000	11.500 UF	\$1.200.000

5.3.4. Penalización por Deudas

Si el usuario menciona deudas o cupo de tarjetas de crédito, el sistema reduce proporcionalmente su capacidad:

- Factor de reducción: 3 % por cada millón de cupo utilizado
- Reducción máxima: 30 % de la capacidad total

5.4. Integración con el Backend

Cuando el chatbot recopila suficiente información, genera automáticamente un **payload JSON** que se envía al backend para ejecutar la búsqueda:

```
1 {  
2   "precio_min": 2500,  
3   "precio_max": 3200,  
4   "tipo_inmueble_preferido": "Departamento",  
5   "comunas_preferidas": ["Nunoa"],  
6   "dormitorios_min": 2,  
7   "peso_precio": 0.25,  
8   "peso_transporte": 0.20,  
9   "peso_educacion": 0.15,  
10  "peso_salud": 0.15,  
11  "peso_areas_verdes": 0.10  
12 }
```

Listing 1: Ejemplo de payload generado por el chatbot

5.5. Presentación de Resultados

Una vez que el backend retorna las propiedades recomendadas, el chatbot las analiza y presenta de forma amigable:

- Resume el número total de propiedades encontradas
- Destaca las 3-5 mejores opciones según el score de satisfacción
- Menciona puntos fuertes de cada propiedad (cercanía a metro, áreas verdes, etc.)
- Ofrece ver más detalles o refinar la búsqueda
- Muestra las propiedades en el mapa interactivo

5.6. Tecnologías de Implementación

El chatbot está implementado en Vue.js 3 con las siguientes características técnicas:

- **SDK de Gemini:** @google/genai (versión 2025)
- **Modelo de IA:** gemini-2.5-flash con temperatura 0.7
- **Contexto máximo:** 2048 tokens de salida
- **Formato de respuesta:** Markdown con bloques de código para payloads

- **Detección de datos financieros:** Expresiones regulares para español chileno
- **Persistencia de sesión:** Historial de conversación mantenido en memoria

Esta integración permite que TerraMatch ofrezca una experiencia de usuario completa, combinando la precisión del modelo predictivo con la accesibilidad de una interfaz conversacional natural.

6. Resultados

6.1. Caracterización del Dataset Inmobiliario

El dataset final comprende 7.702 propiedades distribuidas heterogéneamente entre las cuatro comunas. La composición muestra un predominio de departamentos (66.7%) sobre casas (33.3%), reflejando la estructura del mercado inmobiliario en zonas urbanas consolidadas.

Gráfico 1: Histogramas de Variables Clave




Figura 7: Distribución de variables principales: precio (UF), superficie útil (m²), dormitorios y baños

Las distribuciones revelan patrones característicos:

- **Precio:** Asimetría positiva con concentración en rangos medios (2.000-5.000 UF)
- **Superficie:** Patrón bimodal asociado a departamentos (40-60 m²) y casas (120-180 m²)
- **Dormitorios:** Predominio de 2-3 dormitorios (72% del total)
- **Baños:** Mayoría con 1-2 baños (85% del total)

Tabla 7: Estadísticas descriptivas del dataset inmobiliario

Variable	Media	Mediana	Desv. Est.	Rango
Precio (UF)	5.847	4.200	5.123	800 - 73.000
Superficie útil (m ²)	78.4	62.0	48.7	16 - 900
Precio/m ² (UF)	89.2	82.5	35.4	28 - 280
Dormitorios	2.4	2	0.9	1 - 8
Baños	1.8	2	0.7	1 - 6

6.2. Análisis por Comuna

Las cuatro comunas presentan perfiles inmobiliarios diferenciados:

Gráfico 2: Análisis por Comuna




Figura 8: Análisis comparativo de propiedades por comuna: distribución de precios, superficies y características




Figura 9: Análisis detallado de características espaciales por comuna

Santiago Centro presenta la mayor concentración de servicios y el precio por m² más elevado, reflejando su carácter de centro administrativo y comercial. **Estación Central** destaca por su alta conectividad de transporte (estación intermodal) pero con déficit relativo en áreas verdes. **Nuñoa** ofrece un balance entre servicios barriales y calidad residencial, mientras que **La Reina** presenta mayor heterogeneidad morfológica con predominio de vivienda unifamiliar.

6.3. Estadísticas de Accesibilidad

Los índices de accesibilidad revelan diferencias significativas entre comunas y dimensiones:

Tabla 8: Índices promedio de accesibilidad por dimensión (escala 1-10)

Dimensión	Media	Desv. Est.	Mín	Máx
Educación	5.79	1.84	1.2	9.8
Salud	4.36	2.12	0.5	9.5
Transporte	3.60	2.66	0.1	9.9
Entorno	4.68	1.95	0.8	9.2
Seguridad	3.74	2.08	0.3	9.1
Comercio	2.00	1.87	0.1	8.7
Habitabilidad Global	4.03	1.52	1.1	8.4

La dimensión de **Educación** presenta la mayor accesibilidad promedio (5.79), reflejando la buena cobertura escolar en el área de estudio. En contraste, **Comercio** muestra el valor más bajo (2.00), indicando concentración de servicios comerciales en zonas específicas.




Figura 10: Mapa del índice de habitabilidad global calculado a partir de las características espaciales

6.4. Análisis de Correlaciones

El análisis de correlaciones entre variables revela relaciones esperadas y consistentes con la teoría:




Figura 11: Matriz de correlaciones entre variables de propiedades y características espaciales

Hallazgos principales:

- Correlación positiva fuerte entre precio y superficie ($r = 0.68$)
- Correlación negativa entre distancia a áreas verdes y precio ($r = -0.51$)
- Los índices de accesibilidad presentan correlaciones moderadas entre sí ($r = 0.3-0.5$)
- El precio por m^2 correlaciona negativamente con la distancia al centro

6.5. Rendimiento de los Modelos Predictivos

Se entrenaron y evaluaron dos modelos de Machine Learning para predecir el proxy de satisfacción residencial:

Tabla 9: Comparación de rendimiento: Random Forest vs. LightGBM


Modelo	R^2	RMSE	MAE
Random Forest (baseline)	0.8431	0.3598	0.2813
LightGBM (final)	0.8635	0.3357	0.2661

El modelo LightGBM superó al baseline Random Forest en todas las métricas, alcanzando un R^2 de **0.8635**, lo que indica que el modelo explica el 86.35 % de la varianza en la satisfacción residencial. La validación cruzada de 5 folds confirmó la estabilidad del modelo ($R^2 = 0.8650 \pm 0.0078$).

Tabla 10: Métricas detalladas del modelo LightGBM final

Métrica	Valor
R^2 (Test)	0.8635
RMSE (Test)	0.3357
MAE (Test)	0.2661
R^2 Cross-Validation (5-fold)	0.8650 ± 0.0078
Propiedades de entrenamiento	6.162
Propiedades de prueba	1.540
Características predictoras	42

Gráfico 4: Diagramas de Dispersión

Figura 12: Gráfico de dispersión: satisfacción predicha vs. satisfacción real ($R^2 = 0.8635$)

6.6. Importancia de Variables

El análisis de importancia de variables revela el peso relativo de cada factor en la predicción:




Figura 13: Importancia de las 20 principales variables en el modelo predictivo LightGBM

Las variables más importantes son:

- 1. **Distancia a centros de salud** (50 % de importancia): Factor dominante en la predicción
- 2. **Precio por m²** (16 %): Refleja el valor económico relativo
- 3. **Densidad comercial en 600m** (8 %): Acceso a servicios básicos
- 4. **Distancia a transporte** (7 %): Conectividad urbana
- 5. **Superficie útil** (5 %): Espacio disponible

Este resultado valida la hipótesis H1: las variables espaciales (especialmente salud y transporte) aportan una fracción significativa de la importancia total, más allá del precio.

6.7. Validación Espacial

Se evaluó la autocorrelación espacial de los residuos del modelo mediante el Índice de Moran:

Tabla 11: Análisis de autocorrelación espacial de residuos

Indicador		Valor
Índice de Moran (I)		0.0695
p-value		0.082
Z-score		1.74
Interpretación	Dependencia espacial baja	

El valor de Moran's $I = 0.0695$ (cercano a cero) indica **ausencia de sesgo geográfico significativo** en las predicciones. El modelo captura adecuadamente la estructura espacial de la satisfacción residencial.

6.8. Distribución Espacial de la Satisfacción Predicha



Figura 14: Mapa de satisfacción residencial predicha por el modelo LightGBM en las 4 comunas

El mapa revela un patrón espacial claro:

- **Santiago Centro** concentra los valores más altos de satisfacción predicha (5.5/10 promedio)
- **Estación Central y Ñuñoa** presentan valores intermedios (4.1-4.2/10)
- **La Reina** muestra mayor dispersión con valores más bajos en promedio (3.5/10)

Este gradiente centro-periferia es consistente con la distribución de servicios y accesibilidad en el área metropolitana.

7. Discusión

7.1. Interpretación de Resultados

Los resultados obtenidos confirman la hipótesis central del proyecto: **las variables espaciales influyen significativamente en la satisfacción residencial**, más allá del precio y los atributos físicos de la vivienda. El modelo LightGBM, con un R^2 de 0.8635, demuestra que es posible predecir la satisfacción residencial con alta precisión utilizando una combinación de factores económicos, físicos y espaciales.

El hallazgo más notable es la **dominancia de la distancia a centros de salud** (50 % de importancia), un resultado que puede explicarse por varios factores:

- La pandemia COVID-19 incrementó la valoración de proximidad a servicios de salud
- Los centros de salud actúan como indicadores de urbanización y servicios
- La salud es una necesidad básica transversal a todos los perfiles de usuario

7.2. Verificación de Hipótesis

Tabla 12: Verificación de hipótesis de trabajo

Hipótesis	Estado	Evidencia
H1: Variables espaciales significativas	Validada	65 % de importancia total
H2: Autocorrelación espacial positiva	Parcial	Moran's I = 0.07 (débil)
H3: Variación por perfil de usuario	Validada	Rankings diferenciados
H4: Mejora con variables geoespaciales	Validada	+5 % R^2 vs. baseline

La hipótesis H2 se valida parcialmente: existe autocorrelación espacial pero es débil (Moran's I = 0.0695), lo cual es positivo ya que indica que el modelo captura la mayor parte de la estructura espacial sin dejar patrones residuales significativos.

7.3. Comparación con Literatura

Los resultados son consistentes con estudios previos en contextos urbanos similares:

- Alvarez, Gutierrez et al., 2021 reportan que la accesibilidad a servicios explica 40-60 % de la variación en satisfacción residencial en ciudades latinoamericanas
- Zhang et al., 2019 encuentran que la proximidad a transporte masivo incrementa el valor percibido en 8-15 %

- Hoon et al., 2020 obtienen R^2 de 0.75-0.85 con modelos de ML para predicción inmobiliaria

Nuestro R^2 de 0.8635 se sitúa en el rango superior de la literatura, posiblemente debido a la integración de múltiples fuentes de datos espaciales y la granularidad del análisis.

7.4. Implicancias Prácticas

Los resultados sugieren prioridades claras para política pública e intervención urbana:

1. **Salud:** Ampliar la cobertura de consultorios y centros de salud fuera del centro
2. **Transporte:** Mejorar conectividad en comunas con menor acceso (La Reina)
3. **Comercio:** Fomentar desarrollo de servicios barriales en zonas deficitarias
4. **Áreas verdes:** Fortalecer espacios públicos en zonas de alta densificación

Para el mercado inmobiliario, el sistema TerraMatch ofrece:

- Criterios objetivos para comparar ubicaciones
- Recomendaciones personalizadas según perfil de usuario
- Transparencia en la evaluación de factores de satisfacción

7.5. Limitaciones del Estudio

Es importante reconocer las limitaciones del presente trabajo:

- **Cobertura geográfica:** Solo 4 comunas de la RM, dificultando generalización
- **Variables no observadas:** Antigüedad, calidad de construcción, ruido, contaminación
- **Temporalidad:** Datos estáticos de 2025, sin dinámica de mercado
- **Validación subjetiva:** El proxy de satisfacción no ha sido validado con encuestas reales
- **Distancia euclidiana:** No considera tiempos reales de viaje o barreras físicas

7.6. Trabajo Futuro

Se proponen las siguientes líneas de desarrollo:

1. **Expansión geográfica:** Incorporar más comunas de la RM
2. **Variables adicionales:** Integrar datos de delincuencia, contaminación acústica y calidad del aire
3. **Validación empírica:** Realizar encuestas de satisfacción real para calibrar el modelo
4. **Temporalidad:** Incorporar series de tiempo para capturar dinámica del mercado
5. **Red vial:** Calcular tiempos de viaje reales en lugar de distancias euclidianas

8. Conclusiones

8.1. Síntesis de Hallazgos

El proyecto TerraMatch demuestra la viabilidad técnica y el valor práctico de integrar análisis geoespacial con Machine Learning para estimar la satisfacción residencial en el contexto urbano de Santiago de Chile. Los principales hallazgos son:

1. **Las variables espaciales son determinantes:** La distancia a centros de salud, densidad comercial y acceso a transporte explican más del 65 % de la importancia del modelo predictivo.
2. **Alta capacidad predictiva:** El modelo LightGBM alcanza un R^2 de 0.8635, superando significativamente enfoques basados solo en precio y atributos físicos.
3. **Sin sesgo geográfico:** La baja autocorrelación espacial de residuos (Moran's I = 0.0695) indica que el modelo captura adecuadamente la estructura territorial.
4. **Patrones territoriales claros:** Existe un gradiente centro-periferia en la satisfacción predicha, consistente con la distribución de servicios urbanos.
5. **Diferenciación por perfil:** Los rankings de propiedades varían según el perfil de usuario, validando el enfoque multi-perfil.

8.2. Cumplimiento de Objetivos

Tabla 13: Evaluación del cumplimiento de objetivos específicos

Objetivo	Estado	Evidencia
Integrar 29 datasets geoespaciales	✓	Sección 4.1
Calcular métricas espaciales	✓	42 features calculadas
Diseñar proxy de satisfacción	✓	5 perfiles implementados
Entrenar modelo predictivo	✓	$R^2 = 0.8635$
Implementar dashboard interactivo	✓	Backend + Frontend funcional

8.3. Contribución del Proyecto

TerraMatch realiza las siguientes contribuciones:

- **Metodológica:** Pipeline reproducible para integración de datos geoespaciales con ML
- **Técnica:** Modelo predictivo de alta precisión para satisfacción residencial
- **Aplicada:** Sistema funcional de recomendación inmobiliaria con API REST

- **Territorial:** Caracterización espacial detallada de 4 comunas de Santiago

8.4. Recomendaciones

Para usuarios del sistema:

- Utilizar el dashboard para comparar propiedades objetivamente
- Considerar el perfil de usuario que mejor represente sus necesidades
- Complementar las predicciones con visitas presenciales

Para tomadores de decisión:

- Priorizar inversión en salud y transporte en comunas deficitarias
- Fomentar desarrollo comercial barrial en zonas residenciales
- Considerar métricas de accesibilidad en planificación urbana

8.5. Reflexión Final

El proyecto demuestra que la integración de datos geoespaciales con técnicas de Machine Learning ofrece una perspectiva valiosa para entender y predecir la satisfacción residencial. En un mercado inmobiliario cada vez más competitivo y con barreras de acceso crecientes, herramientas como Terra-Match pueden contribuir a reducir la asimetría de información y apoyar decisiones más informadas.

El enfoque desarrollado es replicable a otras ciudades y contextos, abriendo oportunidades para futuras investigaciones y aplicaciones en el ámbito de la geoinformática urbana.

Referencias

- Alvarez, P., Gutierrez, J., et al. (2021). Urban accessibility and residential satisfaction in Latin America. *Cities*, 116, 103261.
- Anselin, L. (1995). Local Indicators of Spatial Association-LISA. *Geographical Analysis*, 27(2), 93-115.
- BioBio Chile & CIPER Chile. (2025). *Stock de propiedades no vendidas y nuevas oportunidades en el mercado inmobiliario chileno* [Consultado: 2025]. <https://www.biobiochile.cl>
- Bonaiuto, M., Fornara, F., Ariccio, S., et al. (2015). Local identity processes and environmental attitudes in land consolidation. *Journal of Environmental Psychology*, 44, 169-179.
- Brueckner, J. K. (2011). Lectures on Urban Economics.
- Fotheringham, A. S., Brunsdon, C., & Charlton, M. (2002). Geographically Weighted Regression: the analysis of spatially varying relationships. *Annals of the American Association of Geographers*, 92(3), 431-443.
- Freeman, A. M. (2003). *The Measurement of Environmental and Resource Values: Theory and Methods* (2.^a ed.). Resources for the Future.
- Geurs, K. T., & van Wee, B. (2004). Accessibility evaluation of land-use and transport strategies: review and research directions. *Journal of Transport Geography*, 12(2), 127-140.
- Handy, S. L. (1997). Transportation, land use, and the environment. *Journal of Planning Education and Research*, 16(3), 193-204.
- Hoon, O., Park, S., & Lee, K. (2020). Machine learning in housing price prediction. *Applied Sciences*, 10(15), 5393.
- IPSOS. (2025, enero). *Monitor de Viviendas 2025* (Estudio de satisfacción residencial) (Consultora multinacional IPSOS). IPSOS Chile.
- Lancaster, K. J. (1966). A new approach to consumer theory. *Journal of political economy*, 74(2), 132-157.
- Li, X., Wang, N., & Liu, H. (2020). Deep learning for real estate price prediction. *IEEE Access*, 8, 43883-43896.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 4765-4774.
- Lynch, A. (2025). Predict House Prices 5x Faster with LightGBM vs XGBoost. *Medium*.
- Marans, R. W. (2015). Housing as a Reflection of Values, Psychological Needs, and the Achievement of Well-being in Germany. *Housing and Society*, 42(2), 115-135.
- O'Sullivan, D., & Unwin, D. J. (2010). *Geographic Information Analysis* (2.^a ed.). John Wiley & Sons.
- Park, B. H. (2020). Evaluating Residential Satisfaction in Korean New Towns. *Urban Studies*, 57(4), 823-841.
- Rosen, S. (1974). Hedonic prices and implicit markets: product differentiation in pure competition. *Journal of political economy*, 82(1), 34-55.

- Talen, E. (2003). Measuring urbanism: Issues in smart growth research. *Journal of Urban Design*, 8(2), 113-125.
- Wei, Y. C. (2018). Accessibility analysis and evaluation methodology. *Transportation Research Procedia*, 31, 82-92.
- Zhang, W., Wang, M., & Li, L. (2019). Accessibility analysis and housing prices in Chinese cities. *Landscape and Urban Planning*, 191, 103640.

A. Anexos

A.1. Anexo A: Tablas Complementarias

Tabla 14: Detalle de las comunas del área de estudio

Comuna	Coordenadas	Superficie	Altitud
Estación Central	33°27'07"S 70°40'44"O	14.1 km ²	512 m
La Reina	33°27'00"S 70°33'00"O	23.4 km ²	680 m
Ñuñoa	33°28'00"S 70°36'00"O	16.9 km ²	560 m
Santiago Centro	33°27'00"S 70°40'00"O	22.4 km ²	520 m

Tabla 15: Fuentes de datos geoespaciales utilizadas

Categoría	Formato	Fecha	Acceso
Propiedades inmobiliarias	GeoJSON	2025	Web scraping
Estaciones de metro	GeoJSON	2025	Metro de Santiago
Establecimientos educación	GeoJSON	2024	MINEDUC
Centros de salud	GeoJSON	2024	MINSAL
Servicios comerciales	GeoJSON	2025	OpenStreetMap
Áreas verdes	GeoJSON	2024	IDE Chile
Comisarías y bomberos	GeoJSON	2024	Carabineros

A.2. Anexo B: Figuras Adicionales




Figura 15: Panel de estadísticas descriptivas del dataset inmobiliario




Figura 16: Análisis detallado de correlaciones entre variables



Figura 17: Vista del dashboard de TerraMatch

A.3. Anexo C: Cronograma Ejecutado




Figura 18: Carta Gantt sintética del proyecto

A.4. Anexo D: Enlaces y Recursos

- **Repositorio principal:** <https://github.com/FelipeBaeza/GeoInformatica>
- **Backend (API):** <https://github.com/valecit-a/geo-proyect-backend>
- **Frontend (Dashboard):** <https://github.com/Linna-Lpz/geo-proyect-frontend>
- **Datos procesados:** Disponibles en [autocorrelacion_espacial/](#)