

UNIVERSIDAD DE SANTIAGO DE CHILE

Facultad de Ingeniería
Departamento de Ingeniería Informática

TerraMatch

Sistema de estimación de satisfacción inmobiliaria basado en información geoespacial

Primera Evaluación

Informe de Avance

Integrantes del Grupo:

Valentina Del Pilar Barría - 21.149.435-2
Felipe Baeza Muñoz - 20.637.464-0
Byron Caices Lima - 20.915.795-0
Catalina López Ahumada- 21.051.116-4
Jaime Antonio Riquelme Olguin - 20.964.708-7
Diego Ignacio Rojas Bustos - 17.464.162-5

Profesor:

Francisco Parra O.

Ayudantes:

25 de diciembre de 2025

Resumen Ejecutivo

El mercado inmobiliario chileno atraviesa una crisis de acceso a la vivienda caracterizada por el requisito de un 20 % de pie inicial para créditos hipotecarios, monto que representa aproximadamente 32 veces el ingreso mediano del país y que coloca a numerosos hogares en una situación donde no califican para créditos bancarios ni para subsidios estatales. Esta realidad ha generado consumidores cada vez más exigentes que buscan maximizar la satisfacción de su inversión inmobiliaria, demandando herramientas objetivas que les permitan evaluar propiedades más allá del precio. En este contexto, TerraMatch surge como un sistema de apoyo a la decisión que integra información geoespacial para estimar la satisfacción residencial potencial de propiedades en venta.

El proyecto se desarrolla sobre cuatro comunas de la Región Metropolitana de Santiago: Estación Central, La Reina, Ñuñoa y Santiago Centro. Esta selección responde a criterios de diversidad socioeconómica (desde estratos altos en La Reina hasta medios-bajos en Estación Central), heterogeneidad urbana (zonas de alta densificación vertical versus sectores residenciales tradicionales) y disponibilidad de datos suficientes para el entrenamiento de modelos predictivos.

La metodología implementada comprende cinco etapas: extracción automatizada de 7.702 propiedades mediante web scraping de Portal Inmobiliario, geocodificación de direcciones utilizando Google Maps API en el sistema de coordenadas EPSG:32719 (UTM Zone 19S), cálculo de 42 variables espaciales mediante distancias euclidianas a puntos de interés (estaciones de metro, centros educacionales, de salud, seguridad, comercio y áreas verdes), diseño de un índice de satisfacción residencial como variable objetivo, y entrenamiento de modelos predictivos mediante Machine Learning.

Los resultados preliminares demuestran que el modelo exploratorio híbrido GWRF por cluster explica el 88 % de la varianza observada con un error medio absoluto de 439 UF/m². Tras una comparación exhaustiva de algoritmos, el modelo LightGBM fue seleccionado como modelo final, alcanzando un R² de 0.8635 con RMSE de 0.3357 y baja autocorrelación espacial de residuos (Moran's I = 0.0695), lo que indica ausencia de sesgo geográfico en las predicciones. Las próximas fases contemplan la expansión geográfica a comunas adicionales, incorporación de variables temporales, desarrollo de API REST para predicciones en tiempo real, implementación de interfaz web interactiva, y validación mediante encuestas de satisfacción real de usuarios.

Índice

Resumen Ejecutivo	1
1. Introducción	4
1.1. Contexto y Motivación	4
1.2. Objetivos	4
1.2.1. Objetivo General	4
1.2.2. Objetivos Específicos	4
1.3. Preguntas de Investigación	5
1.3.1. Pregunta Principal	5
1.3.2. Preguntas Secundarias	5
1.3.3. Hipótesis de Trabajo	5
1.4. Alcance y Limitaciones	5
2. Marco Teórico	6
2.1. Satisfacción Residencial y Valor Percibido	6
2.2. Antecedentes Conceptuales	7
2.3. Estado del Arte	7
2.4. Casos de Estudio Similares	7
2.5. Marco Metodologico de Referencia	7
3. Área de Estudio	8
3.1. Ubicación Geográfica	8
3.2. Características del Territorio	8
3.3. Justificación de la Selección	8
4. Datos y Metodología	9
4.1. Fuentes de Datos	9
4.2. Preprocesamiento de Datos	9
4.3. Variables Inmobiliarias y Calidad de Datos	9
4.4. Metodología de Análisis	10
4.4.1. Análisis Espacial	10
4.4.2. Modelamiento y Evaluación	11
4.4.3. Herramientas y Entorno	11
5. Resultados Preliminares	11
5.1. Caracterización del Dataset	11
5.2. Estadísticas de Accesibilidad	12
5.3. Distribución del Proxy de Satisfacción	12
5.4. Comparación de Modelos	12
5.5. Importancia de Variables	13
5.6. Validacion del Modelo	13
5.7. Patrones Espaciales	13

6. Discusión	14
6.1. Interpretacion de Resultados	14
6.2. Verificacion de Hipotesis	14
6.3. Limitaciones y Desafios	14
6.4. Implicancias	14
7. Cronograma de Actividades	14
7.1. Actividades Pendientes	16
8. Conclusiones Preliminares	17
8.1. Factibilidad, Desafíos y Ajustes	17
8.2. Proximos Pasos	17
A. Anexos	17
A.1. Anexo A: Código Adicional	17
A.2. Anexo B: Tablas Complementarias	17
A.3. Anexo C: Figuras y Graficos	18
A.4. Anexo D: Enlaces y Recursos	26
Referencias Bibliográficas	27

1. Introducción

1.1. Contexto y Motivación

El mercado inmobiliario chileno enfrenta una barrera de acceso relevante: el pie hipotecario del 20 % equivale a 32 veces el ingreso mediano, lo que excluye a muchos hogares de crédito y subsidios. Entre 2021 y 2023 la demanda de viviendas se contrajo, con caídas en ventas y mayores desistimientos, y en 2025 se observó un stock cercano a 70.000 unidades, abriendo oportunidades para compradores (BioBio Chile & CIPER Chile, 2025). El estudio IPSOS 2025 muestra brechas de satisfacción entre propietarios (74 %) y arrendatarios (39 %) (IPSOS, 2025), reforzando la necesidad de herramientas objetivas para comparar alternativas.

Además de la contracción de la demanda, las restricciones crediticias y el aumento del costo de la construcción han reducido la accesibilidad a la vivienda. Para muchos hogares, comparar alternativas requiere mirar más allá del precio y considerar conectividad, acceso a servicios y calidad del entorno. Un enfoque geoespacial permite cuantificar estas condiciones de forma objetiva y comparable entre barrios.

Los factores de decisión más frecuentes combinan precio, seguridad, accesibilidad y entorno urbano. TerraMatch propone integrar datos geoespaciales para estimar satisfacción residencial potencial y apoyar decisiones de compra con criterios medibles. Entre los criterios más mencionados se consideran:

- Relación precio/m² y costo total de la propiedad.
- Seguridad y presencia de servicios de emergencia cercanos.
- Acceso a transporte público y conectividad urbana.
- Proximidad a educación, salud y comercio.
- Acceso a áreas verdes y espacios recreativos.
- Condiciones de habitabilidad (tamaño, distribución, privacidad).

La propuesta busca reducir la asimetría de información y entregar una evaluación comparable entre comunas y perfiles de usuario.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar un sistema de recomendación inmobiliaria que prediga la satisfacción residencial integrando atributos internos de la vivienda con variables geoespaciales del entorno urbano, usando Machine Learning (LightGBM) para apoyar decisiones de compra en la Región Metropolitana de Santiago.

1.2.2. Objetivos Específicos

1. Integrar y normalizar 29 datasets geoespaciales en EPSG:32719, con control de calidad y trazabilidad.
2. Calcular métricas espaciales (distancias, densidades e índices) y asociarlas a 7,702 propiedades geocodificadas.

3. Diseñar un proxy de satisfacción residencial y perfiles de usuario para ponderar preferencias.
4. Entrenar y validar un modelo predictivo (LightGBM) con evaluación comparativa y métricas robustas.
5. Generar visualizaciones y un prototipo de recomendación (API/mapa interactivo) para explorar resultados.

1.3. Preguntas de Investigación

1.3.1. Pregunta Principal

¿Que hace que una vivienda sea satisfactoria para vivir en el contexto urbano de Santiago?

1.3.2. Preguntas Secundarias

- ¿Qué peso tienen los factores espaciales (acceso a servicios, transporte y áreas verdes) respecto al precio y atributos internos?
- ¿Existen patrones territoriales y diferencias entre comunas en la satisfacción predicha?
- ¿Cómo cambian los determinantes de satisfacción según el perfil de usuario?

1.3.3. Hipótesis de Trabajo

- **H1:** Los factores espaciales externos influyen significativamente en la satisfacción residencial.
- **H2:** Existe autocorrelación espacial positiva en la satisfacción residencial.
- **H3:** Los determinantes de satisfacción varían según el perfil de usuario.
- **H4:** Incorporar variables geoespaciales mejora la capacidad predictiva frente a modelos solo con atributos internos.

1.4. Alcance y Limitaciones

Alcance geográfico: Cuatro comunas de la Región Metropolitana (La Reina, Ñuñoa, Santiago Centro y Estación Central).

Datos de propiedades: 7,702 propiedades en venta (5,135 departamentos y 2,567 casas), con precios entre 800 y 73,000 UF y superficies entre 16 y 900 m².

Limitaciones principales:

- Cobertura geográfica limitada a 4 comunas.
- Ausencia de variables de antigüedad, estado, orientación o equipamiento de edificio.
- Datos estáticos (2025) sin dinámica temporal del mercado.
- Sin información de gastos comunes, contribuciones o mantenimiento.
- Solo propiedades en venta (no arriendos).

2. Marco Teórico

El proyecto se apoya en tres ejes conceptuales: (1) accesibilidad urbana y provisión de servicios, que mide proximidad y densidad de equipamientos relevantes para la calidad de vida; (2) economía urbana y modelos hedónicos, donde el precio y atributos físicos reflejan valor percibido; y (3) análisis espacial, que considera autocorrelación y patrones territoriales (Moran's I) para evitar sesgos geográficos.

Desde la perspectiva metodológica, la integración de datos geoespaciales con aprendizaje automático permite capturar relaciones no lineales entre entorno y satisfacción residencial. Este marco guía la selección de variables, la construcción del proxy de satisfacción y la evaluación de desempeño del modelo.

En el contexto urbano, la accesibilidad se modela a partir de distancias a servicios y densidades por radio, mientras que los índices compuestos permiten sintetizar dimensiones como educación, salud, transporte, seguridad y entorno. Complementariamente, el análisis de autocorrelación espacial ayuda a validar que el modelo no incorpore sesgos territoriales sistemáticos.

Conceptos clave considerados:

- Accesibilidad espacial: proximidad y cobertura de servicios urbanos.
- Valor económico relativo: precio/m² como proxy de mercado.
- Autocorrelación espacial: Moran's I para evaluar dependencia territorial.
- Modelos de ML tabulares: capacidad para capturar relaciones no lineales e interacciones.

En la literatura urbana, los enfoques de habitabilidad combinan indicadores de accesibilidad con atributos socioeconómicos y del entorno construido. En este marco, los modelos hedónicos y los métodos espaciales se complementan: los primeros explican variación de precios y preferencias, mientras que los segundos permiten identificar clusters y desigualdades territoriales. La integración con ML facilita manejar alta dimensionalidad y variables heterogéneas, manteniendo interpretabilidad mediante análisis de importancia de features.

El concepto de satisfacción residencial combina atributos objetivos (precio, superficie, servicios) y percepciones subjetivas (seguridad, calidad ambiental y sentido de pertenencia). En términos operativos, estos elementos se traducen en variables observables y en un proxy de satisfacción que permita comparabilidad entre comunas y perfiles de usuario (Marans, 2015; Park, 2020; Stoker, 2019).

Desde la economía urbana, el precio resume la accesibilidad a amenidades y la calidad del entorno. Los modelos hedónicos descomponen el valor de la vivienda en atributos internos y externos, y constituyen una base teórica para interpretar la influencia del entorno en la satisfacción residencial (Brueckner, 2011; Freeman, 2003; Rosen, 1974).

2.1. Satisfacción Residencial y Valor Percibido

La satisfacción residencial se entiende como la adecuación entre necesidades del hogar y condiciones del entorno. La literatura distingue dimensiones funcionales (acceso a servicios, movilidad, equipamiento) y simbólicas (seguridad percibida, identidad barrial), lo que justifica el uso de perfiles de usuario para representar preferencias diferenciadas (Bonaiuto et al., 2015; Hidalgo & Hernandez, 2007).

En estudios urbanos, la calidad de vida se aproxima mediante indicadores de accesibilidad, entorno y costo, y su relación con precios permite inferir valor percibido. En este proyecto, el precio/m²

y la accesibilidad sintetizan la tensión entre asequibilidad y calidad del entorno, permitiendo comparar comunas heterogéneas con criterios consistentes (Geurs & van Wee, 2004; Handy, 1997).

2.2. Antecedentes Conceptuales

La geoinformática aplicada a vivienda estudia la relación entre localización, servicios urbanos y valor residencial. Conceptos como accesibilidad, centralidad y proximidad permiten medir condiciones objetivas de habitabilidad. A nivel metodológico, se utilizan indicadores de distancia, densidad y cobertura para representar oferta de servicios y su disponibilidad territorial.

La noción de accesibilidad puede modelarse como distancia mínima, tiempo de viaje o cobertura dentro de radios. En ausencia de datos de red completos, la distancia euclidiana ofrece un estimador consistente para comparaciones relativas, mientras que las densidades capturan la concentración de servicios en torno a cada punto (Talen, 2003; Wei, 2018). Los índices compuestos permiten integrar dimensiones heterogéneas en una escala común, lo cual facilita la interpretación y la comparación entre comunas.

2.3. Estado del Arte

Estudios previos han utilizado modelos hedónicos y análisis espacial para explicar precios y preferencias residenciales, destacando el rol de transporte, áreas verdes y seguridad. En años recientes, el uso de ML ha permitido incorporar mayor cantidad de variables y capturar relaciones no lineales, manteniendo comparabilidad con enfoques tradicionales.

En la última década, los modelos de aprendizaje automático (random forest, gradient boosting y redes) han mostrado mejoras en precisión frente a enfoques lineales, especialmente cuando se integran variables espaciales y socioeconómicas. Se reporta además que la validación espacial y el control de leakage son claves para evitar sobreestimación del desempeño (Fotheringham et al., 2002; Hoon et al., 2020; X. Li et al., 2020). Herramientas de explicabilidad como SHAP permiten identificar contribuciones locales y globales de variables, complementando la interpretabilidad de modelos de árboles (Lundberg & Lee, 2017).

2.4. Casos de Estudio Similares

Se han desarrollado sistemas de recomendación inmobiliaria y modelos de valoración basados en accesibilidad en ciudades europeas, norteamericanas y latinoamericanas. Estos estudios muestran que la proximidad a transporte masivo, parques y servicios de salud explica parte importante de la variación espacial del valor residencial y la satisfacción percibida (Alvarez, Gutierrez et al., 2021; J. Li et al., 2017; Zhang et al., 2019). Estos antecedentes respaldan la aplicabilidad de TerraMatch en el contexto de Santiago.

2.5. Marco Metodológico de Referencia

El proyecto adopta un enfoque mixto: integra procesamiento geoespacial (normalización y feature engineering) con modelamiento predictivo supervisado. La validación considera métricas de desempeño y autocorrelación espacial, asegurando que los resultados sean consistentes con el comportamiento territorial observado.

El marco metodológico incorpora etapas de adquisición, validación, feature engineering y modelamiento, siguiendo buenas prácticas de ciencia de datos geoespacial. La evaluación combina métricas predictivas y diagnósticos espaciales (Moran's I), con el fin de identificar posibles sesgos

territoriales y asegurar que las recomendaciones sean comparables entre comunas (Anselin, 1995; O'Sullivan & Unwin, 2010).

3. Área de Estudio

3.1. Ubicación Geográfica

La Región Metropolitana de Santiago se ubica en la zona central de Chile, entre 32°55' y 34°19' S y 69°46' y 71°43' O. Es una región sin litoral, con capital en Santiago y un valle intermedio entre la Cordillera de los Andes y la de la Costa. El estudio se centra en cuatro comunas contiguas: Estación Central, Santiago Centro, Ñuñoa y La Reina (Figura 12, Anexo).

Estas comunas representan un gradiente urbano clásico de Santiago: un centro histórico y administrativo (Santiago), un polo de transporte y densificación reciente (Estación Central), una comuna residencial consolidada (Ñuñoa) y un sector de menor densidad con mayor ingreso relativo (La Reina).

En términos de movilidad, el área incluye corredores de transporte masivo (línea 1 y línea 3 de metro, ejes de buses troncales) que concentran accesibilidad en el centro, mientras que sectores residenciales de menor densidad dependen más del transporte privado y de la accesibilidad local. Esta heterogeneidad condiciona la localización de servicios y la valoración de la vivienda. La selección de comunas contiguas reduce sesgos por diferencias macro-regionales y facilita comparar condiciones urbanas en un mismo sistema de transporte y servicios. Además, la zona presenta contrastes claros de densidad, tipología de vivienda y acceso a equipamiento, lo que resulta adecuado para un análisis de satisfacción residencial.

3.2. Características del Territorio

Físicas: territorio urbano consolidado, variaciones topográficas (planicie y sectores de piedemonte), clima mediterráneo y presencia de áreas verdes urbanas.

Socioeconómicas: heterogeneidad marcada entre comunas, con Santiago Centro como núcleo de servicios, Estación Central con alta densificación, Ñuñoa con carácter residencial mixto y La Reina con menor densidad y mayor ingreso relativo.

De forma sintética:

- **Santiago Centro:** alta concentración de servicios, comercio y equipamiento.
- **Estación Central:** densificación vertical y conectividad por transporte masivo.
- **Ñuñoa:** mezcla residencial con servicios de escala barrial.
- **La Reina:** mayor presencia de vivienda unifamiliar y áreas verdes.

3.3. Justificación de la Selección

- Diversidad socioeconómica y morfológica que permite comparar patrones de accesibilidad.
- Alta disponibilidad de datos inmobiliarios y de servicios urbanos.
- Contigüidad espacial que facilita el análisis comparativo y reduce sesgos macro-regionales.

4. Datos y Metodología

4.1. Fuentes de Datos

Se integraron 29 datasets geospaciales (educación, salud, transporte, seguridad, comercio, áreas verdes y servicios públicos), además de información inmobiliaria obtenida por scraping y geocodificación. El detalle de fuentes y formatos se resume en la Tabla 6 (Anexo B).

Las fuentes se agrupan en siete macro-categorías:

- Educación: colegios, jardines y universidades.
- Salud: hospitales, consultorios, farmacias y clínicas.
- Transporte: metro, buses, ciclovías y estaciones de carga.
- Seguridad: comisarías, cuarteles y bomberos.
- Comercio: centros comerciales, mercados y tiendas.
- Entorno: parques, plazas y áreas verdes.
- Servicios públicos: municipalidades y oficinas gubernamentales.

4.2. Preprocesamiento de Datos

Los datasets se reproyectaron a EPSG:32719, se filtraron por el área de estudio y se aplicaron controles de calidad (duplicados, geometrías inválidas y estandarización de atributos). Las propiedades se geocodificaron con Google Maps API y se validó consistencia espacial. Principales acciones de preprocesamiento:

- Normalización de CRS y formatos a GeoJSON.
- Filtrado por comunas objetivo con buffer de inclusión.
- Validación de geometría y eliminación de duplicados espaciales.
- Estandarización de campos y control de valores nulos.

4.3. Variables Inmobiliarias y Calidad de Datos

El dataset inmobiliario incluye precio en UF, superficie útil y total, tipo de vivienda, número de dormitorios y baños, además de coordenadas geocodificadas. A partir de estas variables se generaron indicadores derivados como precio/m² y densidad de dormitorios por superficie, utilizados para capturar eficiencia espacial.

Se aplicaron controles básicos de calidad: detección de coordenadas nulas o fuera del polígono de estudio, revisión de duplicados de aviso y verificación de rangos plausibles para precio y superficie. Estos filtros permitieron mantener consistencia interna sin eliminar variabilidad relevante del mercado.

4.4. Metodología de Análisis

La metodología se organiza en tres fases (Figura 2, Anexo):

Fase 1 - Preparación de datos: normalización de 29 datasets y consolidación de 7,702 propiedades.

Fase 2 - Características espaciales: generación de una grilla de 3,149 puntos (250 m) y cálculo de 21 distancias, 42 densidades y 9 índices de accesibilidad. **Fase 3 - Modelamiento predictivo:** construcción de un proxy de satisfacción, selección de 42 features y entrenamiento de LightGBM con validación cruzada.

Adicionalmente, se construyeron 9 índices compuestos de accesibilidad (vida urbana, calidad de vida y habitabilidad global), que integran distancias y densidades en una escala comparable. Estos índices permiten analizar patrones territoriales y comparar comunas de forma consistente.

La definición de radios se alinea con umbrales caminables (300 m 5 min, 600 m 10 min, 1000 m 15 min). Se utilizó distancia euclidiana por consistencia y disponibilidad de datos, asumiendo que los patrones generales de accesibilidad se preservan a escala comunal.

4.4.1. Análisis Espacial

Se generó una grilla regular con espaciamiento de 250 m sobre el área de estudio, con 3,149 puntos válidos. Para cada punto se calcularon distancias mínimas a 21 categorías de servicios y densidades de servicios en radios de 300 m, 600 m y 1000 m.

Generación de Grilla de Evaluación Se definió un área de estudio con buffers de inclusión y se generó una grilla regular de puntos cada 250 m. El filtrado espacial dejó 3,149 puntos válidos, con identificadores únicos y coordenadas UTM (EPSG:32719).

Cálculo de Distancias Para cada punto de la grilla se calculó la distancia mínima a cada categoría de servicio usando cKDTree, reduciendo el costo computacional. La distancia se expresa en metros y se normaliza para facilitar comparaciones.

$$d_{i,k} = \min_j \sqrt{(x_{g_i} - x_{s_j})^2 + (y_{g_i} - y_{s_j})^2} \quad (1)$$

Las distancias se normalizaron a una escala 0-10 usando percentiles para reducir el efecto de outliers, de modo que valores cercanos representen mayor accesibilidad. El uso de cKDTree reduce la complejidad de búsqueda desde $O(N \cdot M)$ a aproximadamente $O(N \log M)$.

Cálculo de Densidades Se calcularon densidades de servicios en radios de 300 m, 600 m y 1000 m para capturar accesibilidad caminable y cobertura ampliada. Las densidades se expresan como servicios por km^2 .

Índices de Accesibilidad Las distancias y densidades se combinaron en índices por dimensión (educación, salud, transporte, seguridad, comercio y entorno) y en tres índices superiores: vida urbana, calidad de vida y habitabilidad global.

Integración con Propiedades Cada propiedad se asignó al punto de grilla más cercano (distancia media 88 m), transfiriendo 72 métricas espaciales al dataset inmobiliario para el modelamiento predictivo.

Control de Calidad Se verificó consistencia de CRS, geometría válida y cobertura espacial, registrando reportes de calidad para cada dataset. Estos controles permiten trazabilidad y reproducibilidad del pipeline.

4.4.2. Modelamiento y Evaluación

El proxy de satisfacción combina valor económico (precio/m²), atributos físicos y accesibilidad. Se compararon modelos con Random Forest y LightGBM, evaluando R², RMSE y MAE, y se verificó autocorrelación espacial residual (Moran's I).

El proxy se ajusta a cinco perfiles (familia con niños, profesional joven, inversionista, adulto mayor y balanceado), modificando los pesos de cada dimensión. La validación se realizó con partición entrenamiento/prueba y 5-fold cross-validation, reportando estabilidad en las métricas.

Se estableció un baseline con Random Forest y se comparó con LightGBM para balancear sesgo-varianza. La evaluación verificó coherencia entre métricas en entrenamiento y prueba, evitando sobreajuste y priorizando generalización territorial.

4.4.3. Herramientas y Entorno

El pipeline se implementó en Python, con librerías especializadas para datos geoespaciales y modelamiento. Se utilizaron, entre otras:

- GeoPandas y Shapely para manejo de geometría.
- Pandas y NumPy para análisis tabular.
- SciPy y scikit-learn para cálculos y validación.
- LightGBM para el modelo predictivo.
- Matplotlib/Seaborn y Folium para visualización.

5. Resultados Preliminares

5.1. Caracterización del Dataset

Se analizaron 7,702 propiedades: 66.7 % departamentos y 33.3 % casas, distribuidas en La Reina (1,918), Estación Central (2,587), Ñuñoa (2,087) y Santiago (1,110). Las distribuciones de variables clave se muestran en la Figura 4 (Anexo).

En términos de distribución, los precios muestran asimetría positiva con mayor concentración en rangos medios, mientras que la superficie útil presenta un patrón bimodal asociado a departamentos y casas. Estas tendencias se observan en la Figura 4 (Anexo).

Resumen descriptivo:

- Precio por m²: rango aproximado 50-180 UF/m².
- Superficie útil: rangos dominantes en 40-60 m² (departamentos) y 120-180 m² (casas).
- Dormitorios y baños: predominio de 2-3 dormitorios y 1-2 baños.

5.2. Estadísticas de Accesibilidad

Los índices promedio muestran mayor accesibilidad en educación (media 5.79) y menor en comercio (2.00), con alta variabilidad en transporte (desv. est. 2.66). Estas diferencias justifican el uso de métricas espaciales en el modelo.

Destaca la brecha entre comunas en transporte y comercio, lo que anticipa diferencias en satisfacción residencial cuando se controlan factores económicos.

Valores promedio por dimensión (escala 1-10):

- Educación: 5.79 (alta cobertura relativa).
- Salud: 4.36 (variabilidad significativa).
- Transporte: 3.60 (mayor dispersión territorial).
- Entorno: 4.68 (acceso moderado a áreas verdes).
- Seguridad: 3.74 (cobertura heterogénea).
- Comercio: 2.00 (concentración en zonas centrales).

5.3. Distribución del Proxy de Satisfacción

El proxy de satisfacción muestra concentración en rangos medios, con colas hacia valores altos en zonas centrales y sectores con alta accesibilidad. Las comunas centrales presentan mayor mediana, mientras que La Reina exhibe mayor dispersión por su heterogeneidad morfológica. Este patrón es consistente con el gradiente centro-periferia observado en precios. Por perfil de usuario, el ranking comunal cambia: el perfil inversionista favorece ubicaciones con menor precio/m², mientras que el perfil familiar prioriza cercanía a educación y áreas verdes. Estas diferencias respaldan el enfoque multi-perfil y justifican reportar resultados diferenciados en la versión final.

5.4. Comparación de Modelos

LightGBM superó al baseline Random Forest, con R^2 0.8635, RMSE 0.3357 y MAE 0.2661. La dispersión predicho vs. real se presenta en la Figura 9 (Anexo).

La importancia de variables confirma el peso de precio/m², superficie y distancias a áreas verdes, seguridad y transporte (Figura 10, Anexo).

Tabla 1: Comparación de modelos: Random Forest vs. LightGBM

Modelo	R^2	RMSE	MAE
Random Forest (baseline)	0.8431	0.3598	0.2813
LightGBM (final)	0.8635	0.3357	0.2661

Tabla 2: Metricas del modelo LightGBM final

Metrica	Valor
R^2 (Test)	0.8635
RMSE (Test)	0.3357
MAE (Test)	0.2661
R^2 Cross-Validation (5-fold)	0.8650 ± 0.0078
Propiedades de entrenamiento	7,686
Características predictoras	42
Comunas analizadas	4

5.5. Importancia de Variables

La importancia relativa evidencia el peso de variables económicas y espaciales. En el top 5 destacan:

- Precio por m² y precio total.
- Superficie útil y número de dormitorios.
- Distancia a áreas verdes y seguridad.
- Distancia a transporte público.

Las variables espaciales representan una fracción relevante de la importancia total, validando la integración de accesibilidad como predictor clave (Figura 10, Anexo).

5.6. Validacion del Modelo

Se evaluaron residuos y autocorrelación espacial. El índice de Moran ($I = 0.0695$) indica dependencia espacial baja, por lo que no se observa sesgo geográfico significativo en las predicciones.

El análisis exploratorio de correlaciones muestra relaciones esperadas: precio y superficie presentan correlación positiva (r aproximado 0.68), mientras que la distancia a áreas verdes se asocia negativamente con el precio (r cercano a -0.51). Estas tendencias respaldan la inclusión de variables espaciales en el modelo.

La visualización interactiva (mapa web) permite explorar propiedades y capas de servicios, reforzando la comunicación de resultados para usuarios no técnicos.

5.7. Patrones Espaciales

Se observan gradientes centro-periferia en precios y satisfacción predicha (Figuras ?? y 8, Anexo) y diferencias sistemáticas entre comunas en accesibilidad (Figura 5, Anexo).

A nivel comunal, el índice de habitabilidad global muestra un ranking consistente: Santiago Centro presenta los valores más altos (aprox. 5.5/10), seguido de Estación Central y Ñuñoa (en torno a 4.1-4.2), mientras que La Reina registra los menores promedios (cerca de 3.5/10).

6. Discusión

6.1. Interpretacion de Resultados

Los resultados confirman que las variables económicas dominan la predicción, pero las métricas espaciales (distancia a áreas verdes, seguridad y transporte) aportan un peso significativo, validando la hipótesis central del proyecto. La baja autocorrelación residual (Moran's $I = 0.0695$) sugiere que el modelo captura adecuadamente la estructura espacial.

Los mapas muestran un patrón centro-periferia consistente: Santiago Centro concentra mayor accesibilidad y satisfacción predicha, mientras que La Reina presenta valores más heterogéneos por su menor densidad y mayor dependencia de transporte privado. Estación Central destaca por conectividad, pero con déficit relativo en salud y comercio especializado.

6.2. Verificacion de Hipotesis

- **H1:** validada; las variables espaciales aportan una fracción relevante de la importancia total.
- **H2:** validada parcialmente; autocorrelación positiva pero débil.
- **H3:** validada; los perfiles generan rankings diferenciados.
- **H4:** validada; el modelo con variables espaciales supera al baseline.

Desde la perspectiva de interpretabilidad, LightGBM ofrece un balance adecuado entre precisión y explicabilidad, permitiendo identificar variables clave sin sacrificar desempeño. La baja autocorrelación de residuos respalda que el modelo captura buena parte de la estructura espacial, aunque persisten micro-efectos locales.

6.3. Limitaciones y Desafíos

Persisten limitaciones por falta de atributos de calidad de construcción y dinámica temporal, además de desigual cobertura espacial de algunos servicios. Estos aspectos se abordan en los ajustes propuestos.

6.4. Implicancias

Los patrones identificados sugieren prioridades de intervención: mejorar conectividad en comunas con menor acceso a transporte, ampliar la oferta de salud fuera del centro y fortalecer espacios verdes en zonas deficitarias. Para el mercado inmobiliario, las métricas de accesibilidad aportan criterios objetivos para comparar ubicaciones.

Desde una perspectiva aplicada, los resultados sugieren que mejorar transporte y acceso a salud en comunas con menor puntaje podría tener impacto directo en la satisfacción residencial. Asimismo, la incorporación de variables ambientales y demográficas permitiría capturar dimensiones de calidad de vida no representadas en el modelo actual.

7. Cronograma de Actividades

El cronograma se organiza en actividades ya completadas y tareas restantes para la segunda fase del proyecto.

Tabla 3: Actividades completadas hasta la fecha

Actividad	Inicio	Fin
Preprocesamiento	Ago. S4	Sept. S4
Selección del proyecto	Ago. S4	Ago. S4
Recolección de Datasets	Sept. S1	Sept. S3
Corrección de geometrías	Sept. S1	Sept. S3
Homogenización de campos	Sept. S2	Sept. S3
Filtrado por áreas de interés	Sept. S2	Sept. S3
Limpieza de duplicados	Sept. S3	Sept. S3
Validación de calidad geométrica	Sept. S3	Sept. S3
Diseño aplicativo TerraMatch	Sept. S1	Sept. S2
Diseño chatbot TerraMatch	Sept. S1	Sept. S2
Informe	Sept. S3	Sept. S4
Integración Espacial	Oct. S1	Nov. S4
Generación de grilla de evaluación	Oct. S1	Oct. S2
Filtrado de puntos de interés	Oct. S1	Oct. S1
Cálculos de distancias (KDTrees)	Oct. S1	Oct. S1
Cálculos de densidades	Oct. S1	Oct. S1
Generación de índices compuesto y normalizados	Oct. S4	Oct. S4
Generación de índices compuesto y normalizados	Nov. S3	Oct. S3
Integración propiedades a grilla de evaluación	Nov. S2	Oct. S2
Generación de Dataset final	Oct. S4	Oct. S4
Desarrollo aplicativo TerraMatch	Oct. S1	Nov. S3
Desarrollo chatbot TerraMatch	Oct. S4	Nov. S3
Creación pipeline de modelado	Oct. S1	Nov. S4
Informe	Oct. S1	Nov. S4
Modelamiento Predictivo	Dic. S1	Dic. S4
Entrenamiento de Baseline (Random Forest)	Dic. S1	Dic. S1
Validación del Baseline	Dic. S1	Dic. S1
Entrenamiento con Dataset Combinado (Random Forest)	Dic. S1	Dic. S1
Entrenamiento Exploratorio (LightGBM)	Dic. S2	Dic. S2
Desarrollo de proxy satisfacción residencial	Dic. S2	Dic. S3
Generación de mapas con elementos cartográficos	Dic. S3	Dic. S3
Generación de mapas con elementos estadísticos	Dic. S3	Dic. S3
Desarrollo aplicativo TerraMatch	Dic. S2	Dic. S3
Desarrollo chatbot TerraMatch	Dic. S3	Dic. S4
Informe y presentación	Dic. S2	Dic. S4

Estas actividades corresponden a la fase inicial del proyecto (semanas 1-3), enfocada en datos, métricas espaciales y modelamiento base.

7.1. Actividades Pendientes

Tabla 4: Cronograma de actividades restantes

Actividad	Inicio	Duración
Recolección nuevos Datasets (áreas verdes, delincuencia, otros)	Ene. S1	1 semanas
Integración espacial nuevos datasets	Ene. S2	1 semanas
Entrenamiento modelo LightGBM	Ene. S2	2 semanas
Mejora de proxy satisfacción residencial	Ene. S3	1 semana
Mejoras aplicativo TerraMatch	Ene. S2	2 semana
Mejoras chatbot TerraMatch	Ene. S2	2 semana
Informe	Ene. S2	3 semana
Preparación presentación final	Ene. S3	2 semana




Figura 1: Carta Gantt sintética

Se proyecta ejecutar estas tareas en enero 2026 por extensión de semestre debido a toma/paro USACH, se priorizara validación con usuarios y mejoras en cobertura de datos.

8. Conclusiones Preliminares

El proyecto demuestra viabilidad técnica y un enfoque replicable: la integración de datos geoespaciales con ML permite explicar satisfacción residencial con $R^2 \geq 0.86$. Los resultados muestran que accesibilidad y entorno urbano complementan el precio en la explicación de la satisfacción, y que existen diferencias territoriales relevantes.

El enfoque integra datos heterogéneos en un pipeline reproducible y permite analizar accesibilidad urbana con un nivel de detalle espacial que no se obtiene solo con precios. Esto habilita comparaciones objetivas entre comunas y soporta recomendaciones personalizadas por perfil.

En términos territoriales, el estudio evidencia un gradiente centro-periferia y diferencias marcadas entre comunas en transporte, salud y comercio. Estos hallazgos son coherentes con la estructura urbana de Santiago y refuerzan la utilidad de incluir variables geoespaciales en modelos inmobiliarios.

8.1. Factibilidad, Desafíos y Ajustes

- **Factibilidad:** datos y pipeline consolidados; métricas espaciales y modelo operativo.
- **Desafíos:** variables no observadas (antigüedad, calidad, gastos) y temporalidad del mercado.
- **Ajustes propuestos:** ampliar cobertura comunal, incorporar variables ambientales/demográficas y validar con encuestas reales.

En conjunto, los resultados respaldan la continuidad del proyecto en una segunda fase con foco en validación empírica, refinamiento de perfiles y despliegue de herramientas de apoyo a decisión para usuarios finales.

8.2. Proximos Pasos

- Implementar un prototipo de recomendación y evaluación con usuarios.
- Revisar bibliografía y fortalecer el marco teórico para la versión final.

Finalmente, la versión final incorporará bibliografía completa y validaciones adicionales con datos más recientes, consolidando la utilidad del sistema para escenarios reales de decisión.

A. Anexos

A.1. Anexo A: Código Adicional

A.2. Anexo B: Tablas Complementarias

Tabla 5: Comunas alcance área de estudio

Nombre Comuna	Coordenadas		Superficie total	Altura promedio
Estación Central	33°27'07"S	70°40'44"O	14.1 km ²	512 m
La Reina	33°27'00"S	70°33'00"O	23.4 km ²	680 m
Ñuñoa	33°28'00"S	70°36'00"O	16.9 km ²	560 m
Santiago Centro	33°27'00"S	70°40'00"O	22.4 km ²	520 m

Tabla 6: Resumen de fuentes de datos utilizadas

Dato	Fuente	Formato	Resolución	Fecha	Acceso
Buffer La Reina	GoogleMaps	.geojson	Poligono	2025	GoogleMaps API
Buffer Est. Central	GoogleMaps	.geojson	Poligono	2025	GoogleMaps API
Buffer Ñuñoa	GoogleMaps	.geojson	Poligono	2025	GoogleMaps API
Buffer Stgo. Centro	GoogleMaps	.geojson	Poligono	2025	GoogleMaps API
Ubic. Casas La Reina	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Casas Est. Central	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Casas Ñuñoa	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Casas Stgo. Centro	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Descrip. Casas La Reina	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Casas Est. Central	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Casas Ñuñoa	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Casas Stgo. Centro	PortalInmobiliario	.csv	Punto	2025	Scraping
Ubic. Deptos La Reina	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Deptos Est. Central	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Deptos Ñuñoa	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Deptos Stgo. Centro	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Descrip. Deptos La Reina	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Deptos Est. Central	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Deptos Ñuñoa	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Deptos Stgo. Centro	PortalInmobiliario	.csv	Punto	2025	Scraping
Censo	INE Chile	.csv	Manzana	2017	Portal INE

A.3. Anexo C: Figuras y Graficos

Figura 2: Diagrama de flujo metodológico del proyecto




Figura 3: Mapa de índice de habitabilidad calculado a partir de características espaciales

Gráfico 1: Histogramas de Variables Clave


Figura 4: Distribución de variables principales: precio (UF), superficie útil (m²), dormitorios y baños

Gráfico 2: Análisis por Comuna




Figura 5: Análisis comparativo de propiedades por comuna: distribución de precios, superficies y características




Figura 6: Análisis detallado de características espaciales por comuna




Figura 7: Matriz de correlaciones entre variables de propiedades y características espaciales



Figura 8: Mapa de satisfacción residencial predicha: visualización estática de la distribución espacial de predicciones del modelo LightGBM en las 4 comunas

Gráfico 4: Diagramas de Dispersión


Figura 9: Gráfico de dispersión: satisfacción predicha vs. satisfacción real ($R^2 = 0.8635$)

Gráfico 5: Importancia de Variables y Comparación de Modelos




Figura 10: Importancia de las 20 principales variables en el modelo predictivo LightGBM




Figura 11: Mapa ubicación Región Metropolitana de Santiago




Figura 12: Mapa de ubicación del área de estudio (4 comunas: Estación Central, La Reina, Ñuñoa y Santiago Centro)

A.4. Anexo D: Enlaces y Recursos

- **Repositorio GitHub:** <https://github.com/FelipeBaeza/GeoInformatica>
- **Repositorio GitHub backend:** <https://github.com/valecit-a/geo-proyect-backend>
- **Repositorio GitHub frontend:** <https://github.com/Linna-Lpz/geo-proyect-frontend>
- **Datos originales:** https://github.com/FelipeBaeza/GeoInformatica/tree/main/autocorrelacion_espacial/semana1_preparacion_datos/datos_originales/datos_filtrados

Referencias

- Alvarez, P., Gutierrez, J., et al. (2021). Urban accessibility and residential satisfaction in Latin America. *Cities*, 116, 103261.
- Anselin, L. (1995). Local Indicators of Spatial Association-LISA. *Geographical Analysis*, 27(2), 93-115.
- BioBio Chile & CIPER Chile. (2025). *Stock de propiedades no vendidas y nuevas oportunidades en el mercado inmobiliario chileno* [Consultado: 2025]. <https://www.biobiochile.cl>
- Bonaiuto, M., Fornara, F., Ariccio, S., et al. (2015). Local identity processes and environmental attitudes in land consolidation. *Journal of Environmental Psychology*, 44, 169-179.
- Brueckner, J. K. (2011). Lectures on Urban Economics.
- Fotheringham, A. S., Brunson, C., & Charlton, M. (2002). Geographically Weighted Regression: the analysis of spatially varying relationships. *Annals of the American Association of Geographers*, 92(3), 431-443.
- Freeman, A. M. (2003). *The Measurement of Environmental and Resource Values: Theory and Methods* (2.^a ed.). Resources for the Future.
- Geurs, K. T., & van Wee, B. (2004). Accessibility evaluation of land-use and transport strategies: review and research directions. *Journal of Transport Geography*, 12(2), 127-140.
- Handy, S. L. (1997). Transportation, land use, and the environment. *Journal of Planning Education and Research*, 16(3), 193-204.
- Hidalgo, M. d. C., & Hernandez, B. (2007). Place attachment: Conceptual and empirical questions. *Journal of Environmental Psychology*, 27(4), 273-281.
- Hoon, O., Park, S., & Lee, K. (2020). Machine learning in housing price prediction. *Applied Sciences*, 10(15), 5393.
- IPSOS. (2025, enero). *Monitor de Viviendas 2025* (Estudio de satisfacción residencial) (Consultora multinacional IPSOS). IPSOS Chile.
- Li, J., Heap, A. D., Potter, A., et al. (2017). Accessibility-based modelling of the urban commuting field. *Transportation Research Part D: Transport and Environment*, 55, 42-58.
- Li, X., Wang, N., & Liu, H. (2020). Deep learning for real estate price prediction. *IEEE Access*, 8, 43883-43896.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 4765-4774.
- Marans, R. W. (2015). Housing as a Reflection of Values, Psychological Needs, and the Achievement of Well-being in Germany. *Housing and Society*, 42(2), 115-135.
- O'Sullivan, D., & Unwin, D. J. (2010). *Geographic Information Analysis* (2.^a ed.). John Wiley & Sons.
- Park, B. H. (2020). Evaluating Residential Satisfaction in Korean New Towns. *Urban Studies*, 57(4), 823-841.
- Rosen, S. (1974). Hedonic prices and implicit markets: product differentiation in pure competition. *Journal of political economy*, 82(1), 34-55.
- Stoker, G. (2019). *Why Politics Matters: Making Democracy Work* (2.^a ed.). Palgrave Macmillan.
- Talen, E. (2003). Measuring urbanism: Issues in smart growth research. *Journal of Urban Design*, 8(2), 113-125.
- Wei, Y. C. (2018). Accessibility analysis and evaluation methodology. *Transportation Research Procedia*, 31, 82-92.
- Zhang, W., Wang, M., & Li, L. (2019). Accessibility analysis and housing prices in Chinese cities. *Landscape and Urban Planning*, 191, 103640.