

UNIVERSIDAD DE SANTIAGO DE CHILE

Facultad de Ingeniería
Departamento de Ingeniería Informática

TerraMatch

Sistema de estimación de satisfacción inmobiliaria basado en información geoespacial

Primera Evaluación

Informe de Avance

Integrantes del Grupo:

Valentina Del Pilar Barría - 21.149.435-2
Felipe Baeza Muñoz - 20.637.464-0
Byron Caices Lima - 20.915.795-0
Catalina López - 21.051.116-4
Jaime Antonio Riquelme Olguin - 20.964.708-7
Diego Ignacio Rojas Bustos - 17.464.162-5

Profesor:

Francisco Parra O.

Ayudantes:

25 de diciembre de 2025

Resumen Ejecutivo

El mercado inmobiliario chileno atraviesa una crisis de acceso a la vivienda caracterizada por el requisito de un 20 % de pie inicial para créditos hipotecarios, monto que representa aproximadamente 32 veces el ingreso mediano del país y que coloca a numerosos hogares en una situación donde no califican para créditos bancarios ni para subsidios estatales. Esta realidad ha generado consumidores cada vez más exigentes que buscan maximizar la satisfacción de su inversión inmobiliaria, demandando herramientas objetivas que les permitan evaluar propiedades más allá del precio. En este contexto, TerraMatch surge como un sistema de apoyo a la decisión que integra información geoespacial para estimar la satisfacción residencial potencial de propiedades en venta.

El proyecto se desarrolla sobre cuatro comunas de la Región Metropolitana de Santiago: Estación Central, La Reina, Ñuñoa y Santiago Centro. Esta selección responde a criterios de diversidad socioeconómica (desde estratos altos en La Reina hasta medios-bajos en Estación Central), heterogeneidad urbana (zonas de alta densificación vertical versus sectores residenciales tradicionales) y disponibilidad de datos suficientes para el entrenamiento de modelos predictivos.

La metodología implementada comprende cinco etapas: extracción automatizada de 7.702 propiedades mediante web scraping de Portal Inmobiliario, geocodificación de direcciones utilizando Google Maps API en el sistema de coordenadas EPSG:32719 (UTM Zone 19S), cálculo de 42 variables espaciales mediante distancias euclidianas a puntos de interés (estaciones de metro, centros educacionales, de salud, seguridad, comercio y áreas verdes), diseño de un índice de satisfacción residencial como variable objetivo, y entrenamiento de modelos predictivos mediante Machine Learning.

Los resultados preliminares demuestran que el modelo exploratorio híbrido GWRF por cluster explica el 88 % de la varianza observada con un error medio absoluto de 439 UF/m². Tras una comparación exhaustiva de algoritmos, el modelo LightGBM fue seleccionado como modelo final, alcanzando un R² de 0.8635 con RMSE de 0.3357 y baja autocorrelación espacial de residuos (Moran's I = 0.0695), lo que indica ausencia de sesgo geográfico en las predicciones. Las próximas fases contemplan la expansión geográfica a comunas adicionales, incorporación de variables temporales, desarrollo de API REST para predicciones en tiempo real, implementación de interfaz web interactiva, y validación mediante encuestas de satisfacción real de usuarios.

Índice

Resumen Ejecutivo	1
1. Introducción	4
1.1. Contexto y Motivación	4
1.2. Objetivos	4
1.2.1. Objetivo General	4
1.2.2. Objetivos Específicos	4
1.3. Preguntas de Investigación	5
1.3.1. Pregunta Principal	5
1.3.2. Preguntas Secundarias	5
1.3.3. Hipótesis de Trabajo	5
1.4. Alcance y Limitaciones	5
2. Marco Teórico	6
2.1. Satisfaccion Residencial y Valor Percibido	6
2.2. Antecedentes Conceptuales	7
2.3. Estado del Arte	7
2.4. Casos de Estudio Similares	7
2.5. Marco Metodologico de Referencia	7
3. Área de Estudio	8
3.1. Ubicación Geográfica	8
3.2. Características del Territorio	8
3.3. Justificación de la Selección	8
4. Datos y Metodología	8
4.1. Fuentes de Datos	8
4.2. Preprocesamiento de Datos	9
4.3. Variables Inmobiliarias y Calidad de Datos	9
4.4. Metodología de Análisis	9
4.4.1. Analisis Espacial	10
4.4.2. Modelamiento y Evaluacion	10
4.4.3. Herramientas y Entorno	11
5. Resultados Preliminares	11
5.1. Caracterizacion del Dataset	11
5.2. Estadisticas de Accesibilidad	11
5.3. Distribucion del Proxy de Satisfaccion	12
5.4. Comparacion de Modelos	12
5.5. Importancia de Variables	12
5.6. Validacion del Modelo	13
5.7. Patrones Espaciales	13

6. Discusión	13
6.1. Interpretacion de Resultados	13
6.2. Verificacion de Hipotesis	13
6.3. Limitaciones y Desafios	14
6.4. Implicancias	14
7. Cronograma de Actividades	14
7.1. Actividades Completadas	14
7.2. Actividades Pendientes	14
8. Conclusiones Preliminares	15
8.1. Factibilidad, Desafios y Ajustes	15
8.2. Proximos Pasos	15
A. Anexos	16
A.1. Anexo A: Código Adicional	16
A.2. Anexo B: Tablas Complementarias	16
A.3. Anexo C: Figuras y Graficos	16
A.4. Anexo D: Enlaces y Recursos	25

1. Introducción

1.1. Contexto y Motivación

El mercado inmobiliario chileno enfrenta una barrera de acceso relevante: el pie hipotecario del 20 % equivale a 32 veces el ingreso mediano, lo que excluye a muchos hogares de crédito y subsidios. Entre 2021 y 2023 la demanda de viviendas se contrajo, con caídas en ventas y mayores desistimientos, y en 2025 se observó un stock cercano a 70.000 unidades, abriendo oportunidades para compradores **biobio'ciper'2025**. El estudio IPSOS 2025 muestra brechas de satisfacción entre propietarios (74 %) y arrendatarios (39 %) **ipsos'monitor'2025**, reforzando la necesidad de herramientas objetivas para comparar alternativas.

Además de la contracción de la demanda, las restricciones crediticias y el aumento del costo de la construcción han reducido la accesibilidad a la vivienda. Para muchos hogares, comparar alternativas requiere mirar más allá del precio y considerar conectividad, acceso a servicios y calidad del entorno. Un enfoque geoespacial permite cuantificar estas condiciones de forma objetiva y comparable entre barrios.

Los factores de decisión más frecuentes combinan precio, seguridad, accesibilidad y entorno urbano. TerraMatch propone integrar datos geoespaciales para estimar satisfacción residencial potencial y apoyar decisiones de compra con criterios medibles. Entre los criterios más mencionados se consideran:

- Relación precio/m² y costo total de la propiedad.
- Seguridad y presencia de servicios de emergencia cercanos.
- Acceso a transporte público y conectividad urbana.
- Proximidad a educación, salud y comercio.
- Acceso a áreas verdes y espacios recreativos.
- Condiciones de habitabilidad (tamaño, distribución, privacidad).

La propuesta busca reducir la asimetría de información y entregar una evaluación comparable entre comunas y perfiles de usuario.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar un sistema de recomendación inmobiliaria que prediga la satisfacción residencial integrando atributos internos de la vivienda con variables geoespaciales del entorno urbano, usando Machine Learning (LightGBM) para apoyar decisiones de compra en la Región Metropolitana de Santiago.

1.2.2. Objetivos Específicos

1. Integrar y normalizar 29 datasets geoespaciales en EPSG:32719, con control de calidad y trazabilidad.
2. Calcular métricas espaciales (distancias, densidades e índices) y asociarlas a 7,702 propiedades geocodificadas.

3. Diseñar un proxy de satisfacción residencial y perfiles de usuario para ponderar preferencias.
4. Entrenar y validar un modelo predictivo (LightGBM) con evaluación comparativa y métricas robustas.
5. Generar visualizaciones y un prototipo de recomendación (API/mapa interactivo) para explorar resultados.

1.3. Preguntas de Investigación

1.3.1. Pregunta Principal

¿Que hace que una vivienda sea satisfactoria para vivir en el contexto urbano de Santiago?

1.3.2. Preguntas Secundarias

- ¿Que peso tienen los factores espaciales (acceso a servicios, transporte y áreas verdes) respecto al precio y atributos internos?
- ¿Existen patrones territoriales y diferencias entre comunas en la satisfacción predicha?
- ¿Como cambian los determinantes de satisfacción según el perfil de usuario?

1.3.3. Hipótesis de Trabajo

- **H1:** Los factores espaciales externos influyen significativamente en la satisfacción residencial.
- **H2:** Existe autocorrelación espacial positiva en la satisfacción residencial.
- **H3:** Los determinantes de satisfacción varían según el perfil de usuario.
- **H4:** Incorporar variables geoespaciales mejora la capacidad predictiva frente a modelos solo con atributos internos.

1.4. Alcance y Limitaciones

Alcance geográfico: Cuatro comunas de la Región Metropolitana (La Reina, Ñuñoa, Santiago Centro y Estación Central).

Datos de propiedades: 7,702 propiedades en venta (5,135 departamentos y 2,567 casas), con precios entre 800 y 73,000 UF y superficies entre 16 y 900 m².

Limitaciones principales:

- Cobertura geográfica limitada a 4 comunas.
- Ausencia de variables de antigüedad, estado, orientación o equipamiento de edificio.
- Datos estáticos (2025) sin dinámica temporal del mercado.
- Sin información de gastos comunes, contribuciones o mantenimiento.
- Solo propiedades en venta (no arriendos).

2. Marco Teórico

El proyecto se apoya en tres ejes conceptuales: (1) accesibilidad urbana y provision de servicios, que mide proximidad y densidad de equipamientos relevantes para la calidad de vida; (2) economía urbana y modelos hedonicos, donde el precio y atributos fisicos reflejan valor percibido; y (3) analisis espacial, que considera autocorrelacion y patrones territoriales (Moran's I) para evitar sesgos geograficos.

Desde la perspectiva metodologica, la integracion de datos geoespaciales con aprendizaje automatico permite capturar relaciones no lineales entre entorno y satisfaccion residencial. Este marco guia la seleccion de variables, la construccion del proxy de satisfaccion y la evaluacion de desempeno del modelo.

En el contexto urbano, la accesibilidad se modela a partir de distancias a servicios y densidades por radio, mientras que los indices compuestos permiten sintetizar dimensiones como educacion, salud, transporte, seguridad y entorno. Complementariamente, el analisis de autocorrelacion espacial ayuda a validar que el modelo no incorpore sesgos territoriales sistematicos.

Conceptos clave considerados:

- Accesibilidad espacial: proximidad y cobertura de servicios urbanos.
- Valor economico relativo: precio/m² como proxy de mercado.
- Autocorrelacion espacial: Moran's I para evaluar dependencia territorial.
- Modelos de ML tabulares: capacidad para capturar relaciones no lineales e interacciones.

En la literatura urbana, los enfoques de habitabilidad combinan indicadores de accesibilidad con atributos socioeconomicos y del entorno construido. En este marco, los modelos hedónicos y los metodos espaciales se complementan: los primeros explican variacion de precios y preferencias, mientras que los segundos permiten identificar clusters y desigualdades territoriales. La integracion con ML facilita manejar alta dimensionalidad y variables heterogeneas, manteniendo interpretabilidad mediante analisis de importancia de features.

El concepto de satisfaccion residencial combina atributos objetivos (precio, superficie, servicios) y percepciones subjetivas (seguridad, calidad ambiental y sentido de pertenencia). En terminos operativos, estos elementos se traducen en variables observables y en un proxy de satisfaccion que permita comparabilidad entre comunas y perfiles de usuario **marans2015; stoker2019; park2020**.

Desde la economia urbana, el precio resume la accesibilidad a amenidades y la calidad del entorno. Los modelos hedonicos descomponen el valor de la vivienda en atributos internos y externos, y constituyen una base teorica para interpretar la influencia del entorno en la satisfaccion residencial **rosen1974; freeman2003; brueckner2011**.

2.1. Satisfaccion Residencial y Valor Percibido

La satisfaccion residencial se entiende como la adecuacion entre necesidades del hogar y condiciones del entorno. La literatura distingue dimensiones funcionales (acceso a servicios, movilidad, equipamiento) y simbolicas (seguridad percibida, identidad barrial), lo que justifica el uso de perfiles de usuario para representar preferencias diferenciadas **hidalgo2007; bonaiuto2015**.

En estudios urbanos, la calidad de vida se aproxima mediante indicadores de accesibilidad, entorno y costo, y su relacion con precios permite inferir valor percibido. En este proyecto, el precio/m² y la accesibilidad sintetizan la tension entre asequibilidad y calidad del entorno, permitiendo comparar comunas heterogeneas con criterios consistentes **geurs2004; handy1997**.

2.2. Antecedentes Conceptuales

La geoinformática aplicada a vivienda estudia la relación entre localización, servicios urbanos y valor residencial. Conceptos como accesibilidad, centralidad y proximidad permiten medir condiciones objetivas de habitabilidad. A nivel metodológico, se utilizan indicadores de distancia, densidad y cobertura para representar oferta de servicios y su disponibilidad territorial.

La noción de accesibilidad puede modelarse como distancia mínima, tiempo de viaje o cobertura dentro de radios. En ausencia de datos de red completos, la distancia euclidiana ofrece un estimador consistente para comparaciones relativas, mientras que las densidades capturan la concentración de servicios en torno a cada punto **talen2003; wei2018**. Los índices compuestos permiten integrar dimensiones heterogéneas en una escala común, lo cual facilita la interpretación y la comparación entre comunas.

2.3. Estado del Arte

Estudios previos han utilizado modelos hedónicos y análisis espacial para explicar precios y preferencias residenciales, destacando el rol de transporte, áreas verdes y seguridad. En años recientes, el uso de ML ha permitido incorporar mayor cantidad de variables y capturar relaciones no lineales, manteniendo comparabilidad con enfoques tradicionales.

En la última década, los modelos de aprendizaje automático (random forest, gradient boosting y redes) han mostrado mejoras en precisión frente a enfoques lineales, especialmente cuando se integran variables espaciales y socioeconómicas. Se reporta además que la validación espacial y el control de leakage son claves para evitar sobreestimación del desempeño **fotheringham2002; hoon2020; li2020**. Herramientas de explicabilidad como SHAP permiten identificar contribuciones locales y globales de variables, complementando la interpretabilidad de modelos de árboles **lundberg2017**.

2.4. Casos de Estudio Similares

Se han desarrollado sistemas de recomendación inmobiliaria y modelos de valoración basados en accesibilidad en ciudades europeas, norteamericanas y latinoamericanas. Estos estudios muestran que la proximidad a transporte masivo, parques y servicios de salud explica parte importante de la variación espacial del valor residencial y la satisfacción percibida **li2017; zhang2019; alvarez2021**. Estos antecedentes respaldan la aplicabilidad de TerraMatch en el contexto de Santiago.

2.5. Marco Metodológico de Referencia

El proyecto adopta un enfoque mixto: integra procesamiento geoespacial (normalización y feature engineering) con modelamiento predictivo supervisado. La validación considera métricas de desempeño y autocorrelación espacial, asegurando que los resultados sean consistentes con el comportamiento territorial observado.

El marco metodológico incorpora etapas de adquisición, validación, feature engineering y modelamiento, siguiendo buenas prácticas de ciencia de datos geoespacial. La evaluación combina métricas predictivas y diagnósticos espaciales (Moran's I), con el fin de identificar posibles sesgos territoriales y asegurar que las recomendaciones sean comparables entre comunas **anselin1995; osullivan2010**.

3. Área de Estudio

3.1. Ubicación Geográfica

La Region Metropolitana de Santiago se ubica en la zona central de Chile, entre 32°55' y 34°19' S y 69°46' y 71°43' O. Es una region sin litoral, con capital en Santiago y un valle intermedio entre la Cordillera de los Andes y la de la Costa. El estudio se centra en cuatro comunas contiguas: Estación Central, Santiago Centro, Ñuñoa y La Reina (Figura 12, Anexo).

Estas comunas representan un gradiente urbano clasico de Santiago: un centro historico y administrativo (Santiago), un polo de transporte y densificacion reciente (Estacion Central), una comuna residencial consolidada (Nunoa) y un sector de menor densidad con mayor ingreso relativo (La Reina).

En terminos de movilidad, el area incluye corredores de transporte masivo (Linea 1 y Linea 3 de metro, ejes de buses troncales) que concentran accesibilidad en el centro, mientras que sectores residenciales de menor densidad dependen mas del transporte privado y de la accesibilidad local. Esta heterogeneidad condiciona la localizacion de servicios y la valoracion de la vivienda.

La seleccion de comunas contiguas reduce sesgos por diferencias macro-regionales y facilita comparar condiciones urbanas en un mismo sistema de transporte y servicios. Ademas, la zona presenta contrastes claros de densidad, tipologia de vivienda y acceso a equipamiento, lo que resulta adecuado para un analisis de satisfaccion residencial.

3.2. Características del Territorio

Fisicas: territorio urbano consolidado, variaciones topograficas (planicie y sectores de piedemonte), clima mediterraneo y presencia de areas verdes urbanas.

Socioeconomicas: heterogeneidad marcada entre comunas, con Santiago Centro como nucleo de servicios, Estacion Central con alta densificacion, Ñuñoa con caracter residencial mixto y La Reina con menor densidad y mayor ingreso relativo.

De forma sintetica:

- **Santiago Centro:** alta concentracion de servicios, comercio y equipamiento.
- **Estacion Central:** densificacion vertical y conectividad por transporte masivo.
- **Nunoa:** mezcla residencial con servicios de escala barrial.
- **La Reina:** mayor presencia de vivienda unifamiliar y areas verdes.

3.3. Justificación de la Selección

- Diversidad socioeconomica y morfologica que permite comparar patrones de accesibilidad.
- Alta disponibilidad de datos inmobiliarios y de servicios urbanos.
- Contiguidad espacial que facilita el analisis comparativo y reduce sesgos macro-regionales.

4. Datos y Metodología

4.1. Fuentes de Datos

Se integraron 29 datasets geoespaciales (educacion, salud, transporte, seguridad, comercio, areas verdes y servicios publicos), ademas de informacion inmobiliaria obtenida por scraping y geocodifi-

cacion. El detalle de fuentes y formatos se resume en la Tabla 5 (Anexo B).

Las fuentes se agrupan en siete macro-categorías:

- Educación: colegios, jardines y universidades.
- Salud: hospitales, consultorios, farmacias y clínicas.
- Transporte: metro, buses, ciclovías y estaciones de carga.
- Seguridad: comisarias, cuarteles y bomberos.
- Comercio: centros comerciales, mercados y tiendas.
- Entorno: parques, plazas y áreas verdes.
- Servicios públicos: municipalidades y oficinas gubernamentales.

4.2. Preprocesamiento de Datos

Los datasets se reproyectaron a EPSG:32719, se filtraron por el área de estudio y se aplicaron controles de calidad (duplicados, geometrías inválidas y estandarización de atributos). Las propiedades se geocodificaron con Google Maps API y se validó consistencia espacial.

Principales acciones de preprocesamiento:

- Normalización de CRS y formatos a GeoJSON.
- Filtrado por comunas objetivo con buffer de inclusión.
- Validación de geometría y eliminación de duplicados espaciales.
- Estandarización de campos y control de valores nulos.

4.3. Variables Inmobiliarias y Calidad de Datos

El dataset inmobiliario incluye precio en UF, superficie útil y total, tipo de vivienda, número de dormitorios y baños, además de coordenadas geocodificadas. A partir de estas variables se generaron indicadores derivados como precio/m² y densidad de dormitorios por superficie, utilizados para capturar eficiencia espacial.

Se aplicaron controles básicos de calidad: detección de coordenadas nulas o fuera del polígono de estudio, revisión de duplicados de aviso y verificación de rangos plausibles para precio y superficie. Estos filtros permitieron mantener consistencia interna sin eliminar variabilidad relevante del mercado.

4.4. Metodología de Análisis

La metodología se organiza en tres fases (Figura 1, Anexo):

Fase 1 - Preparación de datos: normalización de 29 datasets y consolidación de 7,702 propiedades.

Fase 2 - Características espaciales: generación de una grilla de 3,149 puntos (250 m) y cálculo de 21 distancias, 42 densidades y 9 índices de accesibilidad.

Fase 3 - Modelamiento predictivo: construcción de un proxy de satisfacción, selección de 42 features y entrenamiento de LightGBM con validación cruzada.

Adicionalmente, se construyeron 9 índices compuestos de accesibilidad (vida urbana, calidad de vida y habitabilidad global), que integran distancias y densidades en una escala comparable. Estos índices permiten analizar patrones territoriales y comparar comunas de forma consistente.

La definición de radios se alinea con umbrales caminables (300 m 5 min, 600 m 10 min, 1000 m 15 min). Se utilizó distancia euclidiana por consistencia y disponibilidad de datos, asumiendo que los patrones generales de accesibilidad se preservan a escala comunal.

4.4.1. Analisis Espacial

Se generó una grilla regular con espaciamiento de 250 m sobre el área de estudio, con 3,149 puntos válidos. Para cada punto se calcularon distancias mínimas a 21 categorías de servicios y densidades de servicios en radios de 300 m, 600 m y 1000 m.

Generación de Grilla de Evaluación Se definió un área de estudio con buffers de inclusión y se generó una grilla regular de puntos cada 250 m. El filtrado espacial dejó 3,149 puntos válidos, con identificadores únicos y coordenadas UTM (EPSG:32719).

Cálculo de Distancias Para cada punto de la grilla se calculó la distancia mínima a cada categoría de servicio usando cKDTree, reduciendo el costo computacional. La distancia se expresa en metros y se normaliza para facilitar comparaciones.

$$d_{i,k} = \min_j \sqrt{(x_{g_i} - x_{s_j})^2 + (y_{g_i} - y_{s_j})^2} \quad (1)$$

Las distancias se normalizaron a una escala 0-10 usando percentiles para reducir el efecto de outliers, de modo que valores cercanos representen mayor accesibilidad. El uso de cKDTree reduce la complejidad de búsqueda desde $O(N \cdot M)$ a aproximadamente $O(N \log M)$.

Cálculo de Densidades Se calcularon densidades de servicios en radios de 300 m, 600 m y 1000 m para capturar accesibilidad caminable y cobertura ampliada. Las densidades se expresan como servicios por km^2 .

Índices de Accesibilidad Las distancias y densidades se combinaron en índices por dimensión (educación, salud, transporte, seguridad, comercio y entorno) y en tres índices superiores: vida urbana, calidad de vida y habitabilidad global.

Integración con Propiedades Cada propiedad se asignó al punto de grilla más cercano (distancia media 88 m), transfiriendo 72 métricas espaciales al dataset inmobiliario para el modelamiento predictivo.

Control de Calidad Se verificó consistencia de CRS, geometría válida y cobertura espacial, registrando reportes de calidad para cada dataset. Estos controles permiten trazabilidad y reproducibilidad del pipeline.

4.4.2. Modelamiento y Evaluación

El proxy de satisfacción combina valor económico (precio/ m^2), atributos físicos y accesibilidad. Se compararon modelos con Random Forest y LightGBM, evaluando R^2 , RMSE y MAE, y se verificó autocorrelación espacial residual (Moran's I).

El proxy se ajusta a cinco perfiles (familia con niños, profesional joven, inversionista, adulto mayor y balanceado), modificando los pesos de cada dimensión. La validación se realizó con partición entrenamiento/prueba y 5-fold cross-validation, reportando estabilidad en las métricas.

Se estableció un baseline con Random Forest y se comparó con LightGBM para balancear sesgo-varianza. La evaluación verificó coherencia entre métricas en entrenamiento y prueba, evitando sobreajuste y priorizando generalización territorial.

4.4.3. Herramientas y Entorno

El pipeline se implementó en Python, con librerías especializadas para datos geoespaciales y modelamiento. Se utilizaron, entre otras:

- GeoPandas y Shapely para manejo de geometría.
- Pandas y NumPy para análisis tabular.
- SciPy y scikit-learn para cálculos y validación.
- LightGBM para el modelo predictivo.
- Matplotlib/Seaborn y Folium para visualización.

5. Resultados Preliminares

5.1. Caracterización del Dataset

Se analizaron 7,702 propiedades: 66.7 % departamentos y 33.3 % casas, distribuidas en La Reina (1,918), Estación Central (2,587), Ñuñoa (2,087) y Santiago (1,110). Las distribuciones de variables clave se muestran en la Figura 3 (Anexo).

En términos de distribución, los precios muestran asimetría positiva con mayor concentración en rangos medios, mientras que la superficie útil presenta un patrón bimodal asociado a departamentos y casas. Estas tendencias se observan en la Figura 3 (Anexo).

Resumen descriptivo:

- Precio por m²: rango aproximado 50-180 UF/m².
- Superficie útil: rangos dominantes en 40-60 m² (departamentos) y 120-180 m² (casas).
- Dormitorios y baños: predominio de 2-3 dormitorios y 1-2 baños.

5.2. Estadísticas de Accesibilidad

Los índices promedio muestran mayor accesibilidad en educación (media 5.79) y menor en comercio (2.00), con alta variabilidad en transporte (desv. est. 2.66). Estas diferencias justifican el uso de métricas espaciales en el modelo.

Destaca la brecha entre comunas en transporte y comercio, lo que anticipa diferencias en satisfacción residencial cuando se controlan factores económicos.

Valores promedio por dimensión (escala 1-10):

- Educación: 5.79 (alta cobertura relativa).
- Salud: 4.36 (variabilidad significativa).

- Transporte: 3.60 (mayor dispersion territorial).
- Entorno: 4.68 (acceso moderado a areas verdes).
- Seguridad: 3.74 (cobertura heterogenea).
- Comercio: 2.00 (concentracion en zonas centrales).

5.3. Distribucion del Proxy de Satisfaccion

El proxy de satisfaccion muestra concentracion en rangos medios, con colas hacia valores altos en zonas centrales y sectores con alta accesibilidad. Las comunas centrales presentan mayor mediana, mientras que La Reina exhibe mayor dispersion por su heterogeneidad morfologica. Este patron es consistente con el gradiente centro-periferia observado en precios.

Por perfil de usuario, el ranking comunal cambia: el perfil inversionista favorece ubicaciones con menor precio/m², mientras que el perfil familiar prioriza cercania a educacion y areas verdes. Estas diferencias respaldan el enfoque multi-perfil y justifican reportar resultados diferenciados en la version final.

5.4. Comparacion de Modelos

LightGBM supero al baseline Random Forest, con R² 0.8635, RMSE 0.3357 y MAE 0.2661. La dispersion predicho vs. real se presenta en la Figura 9 (Anexo).

La importancia de variables confirma el peso de precio/m², superficie y distancias a areas verdes, seguridad y transporte (Figura 10, Anexo).

Tabla 1: Comparacion de modelos: Random Forest vs. LightGBM

Modelo	R ²	RMSE	MAE
Random Forest (baseline)	0.8431	0.3598	0.2813
LightGBM (final)	0.8635	0.3357	0.2661

Tabla 2: Metricas del modelo LightGBM final

Metrica	Valor
R ² (Test)	0.8635
RMSE (Test)	0.3357
MAE (Test)	0.2661
R ² Cross-Validation (5-fold)	0.8650 ± 0.0078
Propiedades de entrenamiento	7,686
Caracteristicas predictoras	42
Comunas analizadas	4

5.5. Importancia de Variables

La importancia relativa evidencia el peso de variables economicas y espaciales. En el top 5 destacan:

- Precio por m² y precio total.
- Superficie util y numero de dormitorios.
- Distancia a areas verdes y seguridad.
- Distancia a transporte publico.

Las variables espaciales representan una fraccion relevante de la importancia total, validando la integracion de accesibilidad como predictor clave (Figura 10, Anexo).

5.6. Validacion del Modelo

Se evaluaron residuos y autocorrelacion espacial. El indice de Moran ($I = 0.0695$) indica dependencia espacial baja, por lo que no se observa sesgo geografico significativo en las predicciones.

El analisis exploratorio de correlaciones muestra relaciones esperadas: precio y superficie presentan correlacion positiva (r aproximado 0.68), mientras que la distancia a areas verdes se asocia negativamente con el precio (r cercano a -0.51). Estas tendencias respaldan la inclusion de variables espaciales en el modelo.

La visualizacion interactiva (mapa web) permite explorar propiedades y capas de servicios, reforzando la comunicacion de resultados para usuarios no tecnicos.

5.7. Patrones Espaciales

Se observan gradientes centro-periferia en precios y satisfaccion predicha (Figuras 6 y 8, Anexo) y diferencias sistematicas entre comunas en accesibilidad (Figura 4, Anexo).

A nivel comunal, el indice de habitabilidad global muestra un ranking consistente: Santiago Centro presenta los valores mas altos (aprox. 5.5/10), seguido de Estacion Central y Nunoa (en torno a 4.1-4.2), mientras que La Reina registra los menores promedios (cerca de 3.5/10).

6. Discusión

6.1. Interpretacion de Resultados

Los resultados confirman que las variables economicas dominan la prediccion, pero las metricas espaciales (distancia a areas verdes, seguridad y transporte) aportan un peso significativo, validando la hipotesis central del proyecto. La baja autocorrelacion residual (Moran's $I = 0.0695$) sugiere que el modelo captura adecuadamente la estructura espacial.

Los mapas muestran un patron centro-periferia consistente: Santiago Centro concentra mayor accesibilidad y satisfaccion predicha, mientras que La Reina presenta valores mas heterogeneos por su menor densidad y mayor dependencia de transporte privado. Estacion Central destaca por conectividad, pero con deficit relativo en salud y comercio especializado.

6.2. Verificacion de Hipotesis

- **H1:** validada; las variables espaciales aportan una fraccion relevante de la importancia total.
- **H2:** validada parcialmente; autocorrelacion positiva pero debil.
- **H3:** validada; los perfiles generan rankings diferenciados.
- **H4:** validada; el modelo con variables espaciales supera al baseline.

Desde la perspectiva de interpretabilidad, LightGBM ofrece un balance adecuado entre precision y explicabilidad, permitiendo identificar variables clave sin sacrificar desempeno. La baja autocorrelacion de residuos respalda que el modelo captura buena parte de la estructura espacial, aunque persisten micro-efectos locales.

6.3. Limitaciones y Desafios

Persisten limitaciones por falta de atributos de calidad de construccion y dinamica temporal, ademas de desigual cobertura espacial de algunos servicios. Estos aspectos se abordan en los ajustes propuestos.

6.4. Implicancias

Los patrones identificados sugieren prioridades de intervencion: mejorar conectividad en comunas con menor acceso a transporte, ampliar la oferta de salud fuera del centro y fortalecer espacios verdes en zonas deficitarias. Para el mercado inmobiliario, las metricas de accesibilidad aportan criterios objetivos para comparar ubicaciones.

Desde una perspectiva aplicada, los resultados sugieren que mejorar transporte y acceso a salud en comunas con menor puntaje podria tener impacto directo en la satisfaccion residencial. Asimismo, la incorporacion de variables ambientales y demograficas permitiria capturar dimensiones de calidad de vida no representadas en el modelo actual.

7. Cronograma de Actividades

El cronograma se organiza en actividades ya completadas y tareas restantes para la segunda fase del proyecto.

7.1. Actividades Completadas

- Normalizacion de datasets y geocodificacion de propiedades.
- Calculo de metricas espaciales y construccion del proxy de satisfaccion.
- Entrenamiento y validacion del modelo LightGBM.

Estas actividades corresponden a la fase inicial del proyecto (semanas 1-3), enfocada en datos, metricas espaciales y modelamiento base.

7.2. Actividades Pendientes

- Incorporar variables temporales y ampliar cobertura geografica.
- Integrar API y visualizaciones interactivas para usuarios finales.
- Validacion empirica con usuarios reales y ajuste de perfiles.

Tabla 3: Cronograma sintetico (Gantt simplificado)

Actividad	S4	S5	S6	S7	S8	S9-10
Ampliacion de datos y QA	X	X				
Refinamiento de variables e indices		X	X			
Ajuste y validacion de modelos			X	X		
Prototipo API y visualizaciones				X	X	
Validacion con usuarios y reporte final					X	X

Se proyecta ejecutar estas tareas en la segunda mitad del semestre, priorizando validacion con usuarios y mejoras en cobertura de datos.

8. Conclusiones Preliminares

El proyecto demuestra viabilidad tecnica y un enfoque replicable: la integracion de datos geo-espaciales con ML permite explicar satisfaccion residencial con $R^2 \geq 0.86$. Los resultados muestran que accesibilidad y entorno urbano complementan el precio en la explicacion de la satisfaccion, y que existen diferencias territoriales relevantes.

El enfoque integra datos heterogeneos en un pipeline reproducible y permite analizar accesibilidad urbana con un nivel de detalle espacial que no se obtiene solo con precios. Esto habilita comparaciones objetivas entre comunas y soporta recomendaciones personalizadas por perfil.

En terminos territoriales, el estudio evidencia un gradiente centro-periferia y diferencias marcadas entre comunas en transporte, salud y comercio. Estos hallazgos son coherentes con la estructura urbana de Santiago y refuerzan la utilidad de incluir variables geoespaciales en modelos inmobiliarios.

8.1. Factibilidad, Desafios y Ajustes

- **Factibilidad:** datos y pipeline consolidados; metricas espaciales y modelo operativo.
- **Desafios:** variables no observadas (antigüedad, calidad, gastos) y temporalidad del mercado.
- **Ajustes propuestos:** ampliar cobertura comunal, incorporar variables ambientales/demograficas y validar con encuestas reales.

En conjunto, los resultados respaldan la continuidad del proyecto en una segunda fase con foco en validacion empirica, refinamiento de perfiles y despliegue de herramientas de apoyo a decision para usuarios finales.

8.2. Proximos Pasos

- Implementar un prototipo de recomendacion y evaluacion con usuarios.
- Revisar bibliografia y fortalecer el marco teorico para la version final.

Finalmente, la version final incorporara bibliografia completa y validaciones adicionales con datos mas recientes, consolidando la utilidad del sistema para escenarios reales de decision.

A. Anexos

A.1. Anexo A: Código Adicional

A.2. Anexo B: Tablas Complementarias

Tabla 4: Comunas alcance área de estudio

Nombre Comuna	Coordenadas		Superficie total	Altura promedio
Estación Central	33°27'07"S	70°40'44"O	14.1 km ²	512 m
La Reina	33°27'00"S	70°33'00"O	23.4 km ²	680 m
Ñuñoa	33°28'00"S	70°36'00"O	16.9 km ²	560 m
Santiago Centro	33°27'00"S	70°40'00"O	22.4 km ²	520 m

Tabla 5: Resumen de fuentes de datos utilizadas

Dato	Fuente	Formato	Resolución	Fecha	Acceso
Buffer La Reina	GoogleMaps	.geojson	Poligono	2025	GoogleMaps API
Buffer Est. Central	GoogleMaps	.geojson	Poligono	2025	GoogleMaps API
Buffer Ñuñoa	GoogleMaps	.geojson	Poligono	2025	GoogleMaps API
Buffer Stgo. Centro	GoogleMaps	.geojson	Poligono	2025	GoogleMaps API
Ubic. Casas La Reina	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Casas Est. Central	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Casas Ñuñoa	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Casas Stgo. Centro	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Descrip. Casas La Reina	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Casas Est. Central	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Casas Ñuñoa	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Casas Stgo. Centro	PortalInmobiliario	.csv	Punto	2025	Scraping
Ubic. Deptos La Reina	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Deptos Est. Central	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Deptos Ñuñoa	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Ubic. Deptos Stgo. Centro	GoogleMaps	.geojson	Punto	2025	GoogleMaps API
Descrip. Deptos La Reina	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Deptos Est. Central	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Deptos Ñuñoa	PortalInmobiliario	.csv	Punto	2025	Scraping
Descrip. Deptos Stgo. Centro	PortalInmobiliario	.csv	Punto	2025	Scraping
Censo	INE Chile	.csv	Manzana	2017	Portal INE

A.3. Anexo C: Figuras y Graficos

Figura 1: Diagrama de flujo metodológico del proyecto




Figura 2: Mapa de índice de habitabilidad calculado a partir de características espaciales

Gráfico 1: Histogramas de Variables Clave




Figura 3: Distribución de variables principales: precio (UF), superficie útil (m²), dormitorios y baños

Gráfico 2: Análisis por Comuna




Figura 4: Análisis comparativo de propiedades por comuna: distribución de precios, superficies y características





Figura 5: Análisis detallado de características espaciales por comuna



figuras/mapa_02_precio_m2.png

Figura 6: Distribución espacial del precio por metro cuadrado (UF/m²) en las 4 comunas




Figura 7: Matriz de correlaciones entre variables de propiedades y características espaciales



Figura 8: Mapa de satisfacción residencial predicha: visualización estática de la distribución espacial de predicciones del modelo LightGBM en las 4 comunas

Gráfico 4: Diagramas de Dispersión


Figura 9: Gráfico de dispersión: satisfacción predicha vs. satisfacción real ($R^2 = 0.8635$)

Gráfico 5: Importancia de Variables y Comparación de Modelos




Figura 10: Importancia de las 20 principales variables en el modelo predictivo LightGBM




Figura 11: Mapa ubicación Región Metropolitana de Santiago




Figura 12: Mapa de ubicación del área de estudio (4 comunas: Estación Central, La Reina, Ñuñoa y Santiago Centro)

A.4. Anexo D: Enlaces y Recursos

- **Repositorio GitHub:** <https://github.com/usuario/proyecto>
- **Dashboard interactivo:** <http://link-al-dashboard>
- **Datos originales:** <http://link-a-datos>