

UNIVERSIDAD DE SANTIAGO DE CHILE

Facultad de Ingeniería
Departamento de Ingeniería Informática

TerraMatch

Sistema de estimación de plusvalía basado en información geográfica

Primera Evaluación

Informe de Avance

Integrantes del Grupo:

Felipe Baeza Muñoz - 20.637.464-0

Catalina López - 21.051.116-4

Valentina Del Pilar Barría -21.149.435-2

Jaime Antonio Riquelme Olguin - 20.964.708-7

Diego Ignacio Rojas Bustos - 17.464.162-5

Profesor:

Francisco Parra O.

Ayudantes:

25 de noviembre de 2025

Resumen Ejecutivo

Este proyecto aborda uno de los desafíos importante que hoy los clientes inmobiliarios en Chile enfrentan al momento de buscar una nueva vivienda, las condiciones del mercado y su relacion calidad-precio.

Hoy Chile se ha vuelto pais donde los precios a la vivienda han aumentado considerablemente "Buscar informacion sobr esto.^{en} relacion a sus vecinos en Latinoamerica lo que ha llevado a que los clientes inmobiliarios se vuelvan cada vez mas exigentes al momento de invertir en viviendas "Terramatch" busca dar una mirada objetiva a la plusvalia de la vivienda chilena basada en informacion geospacial correlacionada que permita facilitar la toma de decisiones durante la busqueda de viviendas.

El proyecto integra información interna de propiedades con métricas espaciales para explicar y predecir un proxy de satisfacción residencial (precio por m²) en un conjunto de comunas de Santiago. El área de estudio se encuentra comprendido en el mercado inmobiliario, especialmente enfocado en la valoracion de precios y en la asesoria automatizada.

La metodología empleada incluye [métodos principales]...

El resultado preliminares muestran que el uso de un modelo exploratorio híbrido por cluster (GWR por cluster) para determinar la satisfacción residencial de una vivienda explica el 88 % de la variación observada con error medio absoluto por debajo de 440 UF/m², siendo una metrica aceptable. Los próximos pasos contemplan [siguientes fases]...

Índice

Resumen Ejecutivo	1
1. Introducción	4
1.1. Contexto y Motivación	4
1.2. Objetivos	4
1.2.1. Objetivo General	4
1.2.2. Objetivos Específicos	5
1.3. Preguntas de Investigación	5
1.4. Alcance y Limitaciones	5
2. Marco Teórico	6
2.1. Antecedentes Conceptuales	6
2.2. Estado del Arte	6
2.3. Marco Metodológico de Referencia	6
3. Área de Estudio	6
3.1. Ubicación Geográfica	6
3.2. Características del Territorio	6
3.2.1. Características Físicas	6
3.2.2. Características Socioeconómicas	6
3.3. Justificación de la Selección	6
4. Datos y Metodología	6
4.1. Fuentes de Datos	6
4.2. Preprocesamiento de Datos	7
4.2.1. Limpieza y Validación	7
4.2.2. Transformaciones y Proyecciones	7
4.3. Metodología de Análisis	7
4.3.1. Diagrama de Flujo Metodológico	7
4.3.2. Análisis Espacial	7
4.3.3. Análisis Estadístico	7
5. Resultados Preliminares	7
5.1. Análisis Exploratorio de Datos	7
5.1.1. Estadísticas Descriptivas	7
5.1.2. Distribuciones Espaciales	8
5.2. Primeros Análisis	8
5.2.1. Autocorrelación Espacial	8
5.2.2. Identificación de Patrones	8
5.3. Visualizaciones Interactivas	8
6. Implementación Técnica	8
6.1. Arquitectura del Sistema	8
6.2. Herramientas y Librerías	8
6.3. Código Ejemplo	8
6.4. Reproducibilidad	8

7. Discusión	9
7.1. Interpretación de Resultados Preliminares	9
7.2. Desafíos Encontrados	9
7.3. Ajustes al Plan Original	9
8. Cronograma de Actividades	9
8.1. Actividades Completadas	9
8.2. Actividades Pendientes	9
9. Conclusiones Preliminares	9
9.1. Logros Alcanzados	9
9.2. Factibilidad del Proyecto	10
9.3. Próximos Pasos Críticos	10
A. Anexos	11
A.1. Anexo A: Código Adicional	11
A.2. Anexo B: Tablas Complementarias	11
A.3. Anexo C: Mapas Adicionales	11
A.4. Anexo D: Enlaces y Recursos	11

1. Introducción

1.1. Contexto y Motivación

Segun el estudio "monitor de viviendas 2025" (citar) realizado por la consultora multinacional IPSOS en enero de este año 2025 para Chile, el "60 % de los encuestados estan contentos con la situacion actual de la vivienda", a su vez que "tres de cada cuatro (74 %) propietarios esta satisfecho con su situacion de viviendas" solo cuatro de diez arrendatarios (39 %) dice estar feliz. aun se percibe que por parte de los cliente inmobiliarios existe una mayor dificultad para comprar o arrendar una casa o departamento de lo que fue para sus padres.

Respecto a esto se ha determinado que los principales desafios para los clientes al momento de comprar o arrendar una vivienda se identifican de la siguiente forma:

- Precios altos de la propiedades
- Tasas de interes muy altas
- Aumento de los costos de construccion de viviendas y edificios

Esta dificultad para conseguir vivienda a llevado a que los clientes tomen en consideracion los siguientes aspecto sal momentos de comprar una propiedad:

- Relacion calidad-precio
- Baja tasa de delincuencia
- Buena ubicacion
- Acceso al transporte publico
- Espacio al aire libre
- Privacidad
- Buena infraestructura local

Lo anterior presenta una oportunidad interesante (agregar idea sobre la importancia de la informacion geoespacial)

1.2. Objetivos

1.2.1. Objetivo General

El objetivo de este proyecto es otorgar acceso a informacion geografica relevante y resumida que facilite la toma de decisiones al momento de comprar y/o arrendar viviendas, informacion destinada a potenciales clientes inmobiliarios que hoy se encuentran indecisos al desconocer ciertos aspectos sobre el sector donde desean realizar una inversion monetaria que a con el paso del tiempo se percibe mas alta.

(Agregar las dimensiones importantes para reducir mas el alcance)

Este proyecto abarcara ciertas comunas de la provincia de Santiago de Chile, seleccionadas por su riqueza informativa geoespacial.

1.2.2. Objetivos Específicos

1. Consolidar informacion geoespacial de la provicia de santiago en las dimensiones (Enumerar dimensiones)
2. Delimitar dimensiones a los espacios geograficos de las comunas de (enumerar comunas)
3. Organzar informacion geoespacial basados en las dimensiones propuestas
4. Establecer correlaciones entre la informacion geoespacial para determinar su valor dimensional
5. Definir y aplicar metodo estadisticos para calcular dimensionalidades
6. (revisar)

1.3. Preguntas de Investigación

- ¿Pregunta 1...?
- ¿Pregunta 2...?
- ¿Pregunta 3...?

1.4. Alcance y Limitaciones

Este proyecto actualmente solo proveera informacion para las siguientes comunas:

- Ñuñoa
- Vitacura
- Santiago Centro
- Estacion Central

Y se basara en las siguientes dimensiones para evaluar la satisfacción residencial de una vivienda:

- Rangos de precios
- Tipos de vivienda
- Domitorios y Baños
- Transporte
- Servicios Basicos
- Entretencion
- Trafico

La correlacion de la informacion geoespacial basada en las dimensiones antes vistas por lo que en ocaciones la informacion resultante estara sesgada de otros factores relevantes como los siguientes:

- (revisar)

2. Marco Teórico

2.1. Antecedentes Conceptuales

2.2. Estado del Arte

(Revisar proyecto/memoria del profesor que nos presento su tesis)

2.3. Marco Metodológico de Referencia

(Revisar)

3. Área de Estudio

3.1. Ubicación Geográfica

Figura 1: Mapa de ubicación del área de estudio

3.2. Características del Territorio

3.2.1. Características Físicas

3.2.2. Características Socioeconómicas

3.3. Justificación de la Selección

4. Datos y Metodología

4.1. Fuentes de Datos

La primera semana se centro en la normalización de datos geoespaciales: recolectar fuentes, corregir geometrías, homogeneizar nombres de campos y convertir todo a una misma CRS. Esto dejó una carpeta de "datos normalizados" lista para cálculos espaciales reproducibles. La segunda semana se dedicó a generar una grilla de evaluación, filtrar puntos dentro del área de interés y calcular distancias (KDTree) y densidades (buffers 300/600/1000 m) para más de veinte categorías, obteniendo índices compuestos y normalizados.

La tercera semana integró las propiedades con la grilla para obtener el dataset final de trabajo, aplicó imputaciones y filtrado de outliers, y construyó un pipeline de modelado. Primero entrenamos un Random Forest global como baseline. Tras comprobar que las variables espaciales aportaban señal, entrenamos un Random Forest sobre el dataset combinado (CSV+GeoJSON). Finalmente exploramos estrategias híbridas (GWRF) entrenando Random Forests locales tras particionar el espacio por comuna, por clusters (K-means sobre features espaciales) y por cuantiles de densidad.

La cuarta semana se planificó para ampliar cobertura y comparar modelos hedonicos (OLS) con los predictivos; el repositorio contiene scripts de recolección y limpieza orientados a integrar datos externos si se desea ampliar la muestra.

Tabla 1: Resumen de fuentes de datos utilizadas

Dato	Fuente	Formato	Resolución	Fecha	Acceso
OSM	OpenStreetMap	.osm/shapefile	Vectorial	2024	API/OSMnx
DEM	NASA SRTM	.tif	30m	2023	USGS
Censo	INE Chile	.csv	Manzana	2017	Portal INE
Sentinel-2	Copernicus	.tif	10m	2024	GEE

4.2. Preprocesamiento de Datos

- 4.2.1. Limpieza y Validación
- 4.2.2. Transformaciones y Proyecciones
- 4.3. Metodología de Análisis
 - 4.3.1. Diagrama de Flujo Metodológico

Figura 2: Diagrama de flujo metodológico del proyecto

- 4.3.2. Análisis Espacial
- 4.3.3. Análisis Estadístico

5. Resultados Preliminares

- 5.1. Análisis Exploratorio de Datos
 - 5.1.1. Estadísticas Descriptivas

Las cifras claves de analisis exploratorio para determinar el mejor modelo predictor para este proyecto son:

- 1. **R²**: Fracción de varianza explicada.
- 2. **RMSE**: Error típico (Penaliza más los errores grandes).
- 3. **MAE**: Error medio absoluto.

De donde los experimientos exploratorios basados en modelo Random Forest (RF) determinaron lo siguiente:

Tabla 2: Estadísticas descriptivas delñ modelo predictivo RF sobre los geodatos

Modelo	R ²	RMSE	MAE
RF Original (CSV)	0.2040	3,443 UF/m ²	2,254 UF/m ²
RF Combinado	0.8431	1,471 UF/m ²	605 UF/m ²
RF GWRF (por comuna)	0.7478		
RF GWRF (cluster)	0.8800	1,286 UF/m ²	439 UF/m ²
RF GWRF (densidad)	0.8772		

Dejando claro que el modelo RF GWRF (cluster), es decir la aplicacion del modelo predictivo Random Forest con la optimizacion espacial GWRF por cluster,entrego cifras mas confiables mostrando un modelo con un ajuste optimo (88 %) y con un error mucho menor que sus similes (439 UF/m^2).

5.1.2. Distribuciones Espaciales

(a) Distribución de variable 1

(b) Distribución de variable 2

Figura 3: Mapas de distribución espacial

5.2. Primeros Análisis

5.2.1. Autocorrelación Espacial

5.2.2. Identificación de Patrones

5.3. Visualizaciones Interactivas

6. Implementación Técnica

6.1. Arquitectura del Sistema

6.2. Herramientas y Librerías

- **Lenguaje:** Python 3.10+
- **Geoespacial:** GeoPandas, Shapely, Rasterio, OSMnx
- **Análisis:** NumPy, Pandas, Scikit-learn, PySAL
- **Visualización:** Matplotlib, Folium, Plotly
- **Base de datos:** PostGIS (si aplica)

6.3. Código Ejemplo

```
1 import geopandas as gpd
2 import matplotlib.pyplot as plt
3 from pysal.explore import esda
4
5 # Cargar datos
6 gdf = gpd.read_file('data/area_estudio.shp')
7
8 # Calcular autocorrelacion espacial
9 moran = esda.Moran(gdf['variable'], weights)
10 print(f"Moran's I: {moran.I:.4f}")
11 print(f"P-value: {moran.p_norm:.4f}")
```

Listing 1: Ejemplo de código para análisis espacial

6.4. Reproducibilidad

El código completo está disponible en: <https://github.com/FelipeBaeza/GeoInformatica>

7. Discusión

7.1. Interpretación de Resultados Preliminares

7.2. Desafíos Encontrados

1. **Desafío 1:** Descripción y cómo se abordó/abordará
2. **Desafío 2:** Descripción y cómo se abordó/abordará
3. **Desafío 3:** Descripción y cómo se abordó/abordará

7.3. Ajustes al Plan Original

8. Cronograma de Actividades

8.1. Actividades Completadas

Tabla 3: Actividades completadas hasta la fecha

Actividad	Responsable	Inicio	Fin
Selección del proyecto	Todo el grupo	Semana 1	Semana 1
Revisión bibliográfica	[Nombre]	Semana 2	Semana 3
Descarga de datos	[Nombre]	Semana 3	Semana 4
Análisis exploratorio	Todo el grupo	Semana 4	Semana 4

8.2. Actividades Pendientes

Tabla 4: Cronograma de actividades restantes

Actividad	Responsable	Inicio	Duración
Análisis espacial avanzado	[Nombre]	Semana 5	2 semanas
Modelamiento	[Nombre]	Semana 7	2 semanas
Desarrollo dashboard	Todo el grupo	Semana 9	2 semanas
Documentación final	Todo el grupo	Semana 11	1 semana
Preparación presentación final	Todo el grupo	Semana 12	1 semana

9. Conclusiones Preliminares

9.1. Logros Alcanzados

- Logro 1...
- Logro 2...
- Logro 3...

9.2. Factibilidad del Proyecto

Si buscas un despliegue sencillo y robusto, recomendamos usar el RF combinado (un único modelo) ya que ofrece muy buena relación desempeño-simplicidad (R^2 (UTF caracater similar) 0.843). Si la prioridad es la máxima precisión y se puede asumir gestión operativa mayor (calcular cluster en tiempo real y mantener varios modelos), desplegar el GWRf por cluster es razonable (R^2 (UTF caracater similar) 0.880, MAE (UTF caracater similar) 439). No recomendamos desplegar modelos por comuna con el dataset actual por falta de muestras locales.

9.3. Próximos Pasos Críticos

1. Expandir cobertura geografica (incorporar nuevas comunas y ciudades) con mayor heterogeneidad
2. Incorporar series temporales para modelar tendencias y estacionalidad.
3. Probar resultados con ensembles avanzados (XGBoost, LightGBM, stacking) tras una fase de tuning.
4. Automatizar el pipeline y desplegar API REST que reviba features y devuelva prediccion y medida de incertidumbre.

A. Anexos

A.1. Anexo A: Código Adicional

A.2. Anexo B: Tablas Complementarias

A.3. Anexo C: Mapas Adicionales

A.4. Anexo D: Enlaces y Recursos

- Repositorio GitHub: <https://github.com/usuario/proyecto>
- Dashboard interactivo: <http://link-al-dashboard>
- Datos originales: <http://link-a-datos>